Machine Vision from the Global South: Synthetic Training, Acquisition Limits and What an Aerial Claim of an Armed Person Must Declare

Luciano Martins Figueira[1], Felipe I. M. Toledo[2] and Hélio Arthur Reis Irigaray[1]

[1] *Fundação Getulio Vargas, Brazilian School of Public and Business Administration (FGV EBAPE), Rio de Janeiro, Brazil*

[2] *High Performance Computing Center and Civil Engineering, COPPE, Federal University of Rio de Janeiro, Rio de Janeiro, Brazil*

Cópia de leitura em português da versão curta submetida em inglês, traduzida em 7 de novembro de 2026. Os números seguem a grafia do original (ponto decimal). A lista de referências fica em inglês. Em caso de dúvida, vale o texto em inglês.

Resumo. Imagens sintéticas são o caminho que este estudo adota para um julgamento visual que se espera cada vez mais que sistemas aéreos sustentem sobre as favelas do Rio de Janeiro, se uma pessoa no solo está armada, porque as alternativas estão fechadas: imagens de moradores não podem ser coletadas com consentimento significativo, e nenhum benchmark público mostra uma favela ou anota uma arma de fogo portada em altitude de levantamento. As operações de segurança pública nesses territórios estão entre as mais letais do Brasil, e a decisão de usar força letal é tomada aqui como dependente desse julgamento. O que chega a um detector é decidido antes de qualquer algoritmo ser escolhido, pela altitude, pela lente, pelo ângulo da câmera e pela luz de cada voo, e tratamos isso como uma questão mensurável. Em corpora gerados proceduralmente de uma favela densa, sem imagens de nenhum território real, caracterizamos o alvo por distância de amostragem do solo (GSD), inclinação da câmera e iluminação, treinamos detectores apenas com imagens sintéticas e os pontuamos contra um teto treinado com igual número de imagens reais, em um benchmark urbano, majoritariamente oblíquo, e em um benchmark nadir em área selvagem; a confusão de armas de fogo com objetos alongados comuns foi medida sinteticamente. Na vertical, a 150 m (4.88 cm por pixel), uma pessoa ocupa 17.6 por 17.5 pixels e a arma de fogo mais larga tem um pixel de largura. O treino apenas sintético alcançou 2.2 por cento do teto para essa aquisição no benchmark urbano e 15.5 por cento com seis assentamentos vistos obliquamente; no benchmark nadir a ordem se inverteu, 68.2 contra 45.8 por cento no par de um só assentamento, com intervalos de execuções sobrepostos. Quando uma pequena fração de imagens reais ficou disponível, o corpus sintético reduziu a acurácia, tanto como pré-treino quanto misturado ao conjunto. Em quadros sintéticos reservados, os detectores classificaram como armado aproximadamente de um em cada cinco a um em cada quatro objetos alongados comuns em toda GSD, uma vez que os três foram treinados sob o mesmo orçamento, e quando os objetos receberam o comprimento de uma arma de fogo a separação desapareceu a 150 m e caiu pela metade a 75 m: na GSD mais grosseira, o que o detector separa é o comprimento, não a forma de uma arma de fogo. A GSD e a geometria de visada em que uma alegação foi testada, e a taxa em que pessoas desarmadas são classificadas como armadas, são o que uma alegação aérea de pessoa armada deve declarar antes de entrar em uma decisão de uso da força, e o que um comando policial, o tribunal que supervisiona as operações e os moradores podem exigir dela.

Palavras-chave: segurança pública; administração pública; discricionariedade algorítmica; dados sintéticos; detecção aérea de objetos; distância de amostragem do solo; uso dual; assentamentos informais

1. Introdução

1.1 Enunciado do problema

Sistemas aéreos já sobrevoam território policiado no Rio de Janeiro: a Polícia Civil usa veículos aéreos não tripulados (UAVs) para inteligência e monitoramento em tempo real de operações (CNN, 2026) nas quais a decisão de usar força letal é tomada aqui como dependente de um único julgamento visual, se a pessoa abordada está armada (Seção 3.4). Propõe-se cada vez mais que uma câmera acima de uma cidade possa fazer essa distinção (Faheem et al., 2025; AlJundi et al., 2025; Kim et al., 2026); o que tais propostas raramente declaram, e o que decide se a distinção é sequer visível, é a condição de aquisição: altitude, sensor e lente, a distância de amostragem do solo (GSD) que produzem, a largura de solo que um pixel abrange, a inclinação da câmera, na vertical (nadir) ou oblíqua, e a iluminação; uma alegação que a omite não pode ser verificada.

As favelas, os assentamentos informais urbanos do Brasil, são pontos cegos dos dados espaciais oficiais, e a tecnologia que poderia mapeá-las pode ser voltada contra moradores que nunca consentiram em ser mapeados (Gevaert, Persello, Sliuzas, & Vosselman, 2016; Watson & Elliott, 2025; West & Bowman, 2016). O Sul Global do título nomeia três condições: não existem imagens aéreas consentidas do território, de modo que toda imagem de treino é sintética; os benchmarks públicos nos quais a transferência pode ser medida mostram uma cidade densa que não é uma favela, majoritariamente de forma oblíqua (Zhu et al., 2022), ou pessoas em área selvagem vistas de cima (Božić-Štulić, Marušić, & Gotovac, 2019); e não existe conjunto de teste público para o que uma pessoa porta na GSD de um voo de levantamento.

1.2 Lacuna de pesquisa

A literatura sobre UAVs mais próxima deste problema planeja trajetórias e patrulhas sobre uma cidade reduzida a uma rede viária, e a pesquisa com UAVs em assentamentos informais serve ao mapeamento, não à segurança (Gevaert et al., 2016; Sithole & Mhangara, 2025; da Silva, Kormann da Silva, & Westerholt, 2024); a interseção entre elas é a lacuna (Seção 2.1). A literatura de administração pública tem acompanhado

o que um instrumento faz com a discricionariedade do agente (Selten, Robeer, & Grimmelikhuijsen, 2023; Meijer, Lorenz, & Wessels, 2021) sob a premissa de que o instrumento vê o que se diz que ele vê; sobre este terreno, essa premissa é a questão em aberto (Seção 3.3). O treino sintético para detecção aérea transfere (Tobin et al., 2017), mas recupera uma fração do que dados reais alcançam para alvos aéreos pequenos (Kiefer, Ott, & Zell, 2022), e nada estabelece quanto um corpus sintético de um assentamento denso recupera em imagens reais, sob quais parâmetros de aquisição, ou a escala em que aquilo que uma pessoa porta deixa de chegar a um detector.

1.3 Objetivo e questões de pesquisa

O objetivo é medir o que um detector treinado apenas com imagens sintéticas recupera da detecção da pessoa, sobre a qual repousa qualquer distinção entre armado e desarmado, como as condições de aquisição deslocam essa fração e, em imagens sintéticas nadir, em qual GSD uma figura portando uma arma de fogo pode ser distinguida de uma portando um objeto comum. Seguem três questões; a Seção 4.6 define os Experimentos A a D.

RQ1. Quanto da acurácia de detecção de pessoas obtida com imagens reais de treino um detector treinado apenas com imagens sintéticas de um assentamento denso recupera em benchmarks aéreos reais públicos, e quais parâmetros de aquisição e de cena (inclinação da câmera, tamanho aparente do alvo, variedade de assentamentos) determinam essa fração? O Experimento A a responde, e o Experimento D acrescenta como a detecção varia com a iluminação em quadros sintéticos.

RQ2. Quando um pequeno número de imagens reais de treino está disponível, 5 ou 10 por cento da partição de treino do benchmark, o corpus sintético acrescenta acurácia, como pré-treino ou misturado ao conjunto de treino? O Experimento B a responde.

RQ3. Apenas em imagens sintéticas, em quais GSDs (4.88, 2.44 e 1.14 cm por pixel a partir de uma câmera nadir, que os rótulos de altitude deste artigo de 150, 75 e 35 m denotam, Seção 4.2.4) um detector consegue separar uma pessoa portando uma arma de fogo de uma portando um objeto alongado comum, e a que taxa ele classifica esta última como armada? O Experimento C a responde sinteticamente.

1.4 Contribuições

O artigo contribui com uma caracterização do alvo aéreo independente de modelo por GSD, inclinação da câmera e iluminação; frações de transferência para detecção de pessoas contra um teto real pareado em um benchmark urbano e em um benchmark nadir, onde a ordem das duas geometrias se inverte; uma transferência negativa (Z. Wang et al., 2019) quando 5 ou 10 por cento de imagens reais existiam, do tipo registrado para treino aéreo com poucas amostras (Shen et al., 2023a, 2023b); uma medição sintética da confusão entre armas de fogo e objetos alongados comuns, com precedentes próximos ao nível do solo (Pérez-Hernández et al., 2020; Torkst et al., 2026); e a posição de que declarar as condições sob as quais uma capacidade não foi demonstrada é a contribuição que incide sobre o uso dual (Seções 6.4 e 7).

2. Trabalhos Relacionados

2.1 Visão de máquina em assentamentos informais e a dimensão vertical

A literatura sobre UAVs mais próxima deste estudo planeja rotas e patrulhas: o planejamento de rotas trata obstáculos tridimensionais com seriedade (Rasoulie & Pashazadeh, 2026; Xu, 2025; Agrawal, Ratnoo, & Ghose, 2017), enquanto o policiamento aéreo os dissolve em formulações planares sobre uma rede viária ou um conjunto de pontos de patrulha (D. Wang & Qian, 2026; Chen, Liu, Hu, Zhang, & Pan, 2025; Yan, Hsieh, & Lai, 2025). A visão de máquina sobre assentamentos informais é um nicho separado, com propósitos de planejamento e humanitários, mapeando a partir de imagens de satélite (Gram-Hansen et al., 2019) ou classificando um assentamento a partir de imagens de drone, onde edificações densas e terreno íngreme desafiam conjuntamente a classificação (Sithole & Mhangara, 2025; Gevaert et al., 2016). No mapeamento, a dimensão vertical entra como altura para classificar o tecido construído; no policiamento aéreo ela não entra de modo algum, e nenhum dos dois pergunta o que um detector vê sobre esse tecido.

2.2 Dados sintéticos e a lacuna sim-to-real na detecção aérea

Este estudo se apoia na randomização de domínio (Tobin et al., 2017; Prakash et al., 2019), aplicada à detecção aérea com texturas randomizadas (Barisic, Petric, & Bogdan, 2022). O benefício relatado dos dados sintéticos é condicional: os ganhos frequentemente foram medidos contra o ImageNet ou contra a inicialização aleatória, e não contra um detector já treinado em imagens reais da classe-alvo (McCormac et al., 2017; Tremblay et al., 2018); os pesos iniciais importam mais quando os dados reais são escassos (He, Girshick, & Dollár, 2019); congelar um extrator de características pré-treinado em imagens reais preservou a detecção (Hinterstoisser et al., 2019); e a transferência negativa (Z. Wang et al., 2019) recorre na detecção aérea de pessoas, em que o pré-treino sintético pontuou abaixo do treino do zero no VisDrone (Yim et al., 2026) e a mistura de imagens sintéticas com reais ficou abaixo da linha de base apenas real no treino com poucas amostras (Shen et al., 2023a, 2023b).

Os dois benchmarks reais usados aqui são o VisDrone-DET (Zhu et al., 2022), cenas urbanas densas vistas majoritariamente de forma oblíqua (Kiefer, Messmer, & Zell, 2021), e o HERIDAL (Božić-Štulić, Marušić, & Gotovac, 2019), imagens nadir de pessoas em terreno natural de 40 a 65 m. Kiefer, Ott e Zell (2022) treinaram três detectores puramente com 40,000 imagens de motor de jogo pareadas às cenas do VisDrone e relataram mAP50 (precisão média, a um limiar de interseção sobre união, IoU, de 0.50) de 1.2, 2.4 e 10.2 contra 24.6, 48.6 e 43.9 para as mesmas arquiteturas treinadas na partição real completa, em 10 classes. Liao et al. (2026) localizam onde a fração sintética é ganha ou perdida para veículos, na origem da geometria e na variação de sol, clima e ângulo de visada (Seção 6.2). Traçados procedurais de favela têm um precedente como conteúdo de jogo (Berwaldt, Bettker, & Pozzer, 2020).

2.3 Detecção aérea de objetos pequenos, GSD e detecção de pessoas e armas

Uma pessoa vista do ar é um objeto pequeno: a família de detectores da Seção 4.5 calcula seu mapa de características mais fino com stride de 8 pixels, de modo que uma instância cujo lado menor fica abaixo de 8 pixels ocupa menos de uma célula desse mapa (Hnoohom, Chotivatunyu, & Jitpattanakul, 2022). A iluminação atua por meio do contraste contra a desordem visual: a sombra das edificações obscurece grande parte das imagens urbanas de alta resolução (Dare, 2005), os detectores de veículos de um benchmark de drones foram piores à luz do dia do que à noite (D. Du et al., 2018), e as especificações de levantamento exigem imagens sem nuvens e uma elevação solar mínima (National Geodetic Survey, 2002; Royal Institution of Chartered Surveyors [RICS], 2021), prática que a Seção 6.3 revisita.

A detecção de armas tem seus próprios benchmarks, nenhum aéreo nas altitudes deste estudo: os que anotam uma arma de fogo portada usam pontos de vista de vigilância (Salazar González et al., 2020; Lim et al., 2021; Ruiz-Santaquiteria et al., 2024; Z. Li et al., 2025); os conjuntos de dados aéreos públicos que rotulam uma pessoa como armada foram capturados de 2 a 8 m acima do solo e rotulam uma ação ou uma gravação, não uma caixa (T. Li et al., 2021; Torkst et al., 2026); e os conjuntos de dados de drone com armas de fogo anotadas são restritos (Faheem et al., 2025) ou não divulgados (AlJundi et al., 2025). Contrapor armas a objetos manuseados da mesma maneira tem precedentes próximos ao nível do solo (Pérez-Hernández et al., 2020; Torkst et al., 2026), e a Seção 4.2.2 adota esse desenho.

3. Contexto do Estudo

3.1 Policiamento, letalidade e controle territorial no Rio de Janeiro

O homicídio doloso no Rio de Janeiro caiu de 63.13 por 100,000 habitantes em 1994 (Instituto de Segurança Pública do Rio de Janeiro [ISP-RJ], n.d.) para 17.1 em 2024 e 2025, enquanto as mortes por intervenção policial no estado subiram de 703 em 2024 para 798 em 2025, 20.5 por cento de todas as mortes violentas intencionais (Fórum Brasileiro de Segurança Pública, 2025, 2026). Em 6 de maio de 2021 a Operação Exceptis, da Polícia Civil no Jacarezinho, matou 27 civis e 1 policial (Human Rights Watch, 2021; Sullivan, Bunker, & da Cruz, 2021). A Arguição de Descumprimento de Preceito Fundamental (ADPF) 635, em curso no Supremo Tribunal Federal (STF) contra a letalidade policial em favelas desde 2019, foi concluída em 3 de abril de 2025 com um plano estadual de redução da letalidade parcialmente homologado (Agência Brasil, 2025; Supremo Tribunal Federal, 2025). Em 28 de outubro de 2025 a Operação Contenção, no Complexo do Alemão e no Complexo da Penha, deixou 121 mortos pela contagem oficial e 132 pela contagem da Defensoria Pública do estado (Couto & Figueiredo, 2025; Fichino, 2025; Fórum Brasileiro de Segurança Pública, 2026), a operação policial mais letal já registrada no Brasil. Por trás desses episódios, organizações criminosas mantêm controle duradouro sobre determinadas favelas (Lessing, 2008; Misse, 2011) e ruas estreitas forçam unidades especiais a deixar seus veículos blindados (Grillo, 2014); a construção empilhada que bloqueia linhas de visada é a premissa deste estudo, não um achado dessas fontes.

3.2 Jacarezinho como caso de referência morfológica

O Jacarezinho, na Zona Norte, está entre as maiores favelas da cidade, com população incerta: 29,766 moradores no censo de 2022 (Instituto Brasileiro de Geografia e Estatística, 2024), aproximadamente 37,000 em números municipais (RioOnWatch, 2019), mais de 60,000 em fontes comunitárias e jornalísticas (Mistler-Ferguson, 2022); o Comando Vermelho o domina há muito tempo. Sua morfologia o torna o caso de referência: construção sobreposta e empilhada verticalmente; becos estreitos; lajes de cobertura ocupadas ou ampliadas; edificações sem geometria padronizada; vias de acesso ausentes dos mapas oficiais; oclusão entre estruturas. Os assentamentos sintéticos da Seção 4.2 aproximam essa morfologia geral, não a geometria do Jacarezinho; nenhuma imagem ou geometria do território entra neles ou em qualquer medição.

3.3 A virada tecnológica na segurança pública

O julgamento entre armado e desarmado chega a um sistema aéreo ao fim de um movimento da discricionariedade relatada depois do fato para a discricionariedade mediada por instrumentos, que a literatura de administração pública acompanhou passo a passo: o uso da força pelo agente de nível de rua (Alcadipani, Lotta, & Cohen, 2024); câmeras corporais (Headley, Baker, & Kang, 2025; Wright, Gaozhao, & Houston, 2024); policiamento preditivo, usado conforme a prática ao seu redor (Meijer, Lorenz, & Wessels, 2021) e deixado de lado quando contradiz a leitura do próprio agente (Selten, Robeer, & Grimmelikhuijsen, 2023); a legitimidade que o público concede a uma força policial que usa inteligência artificial (Gao & Riccucci, 2026); e, com UAVs, vigilância e accountability (West & Bowman, 2016; Frazier, 2016). Cada passo toma como dada a percepção que lhe subjaz; sobre o terreno da Seção 3.2, o que chega a uma câmera é decidido antes que qualquer discricionariedade ou confiança entre em jogo.

3.4 Por que o julgamento entre armado e desarmado é o núcleo ético

Tomamos como premissa, não como achado das fontes citadas, que o fato de a pessoa abordada estar armada é uma categoria central nas decisões de uso de força letal, um julgamento visual feito às pressas em meio a moradores que estão presentes o tempo todo. Os dois erros não são simétricos: deixar de detectar uma pessoa armada priva os policiais de um alerta, enquanto marcar um morador desarmado como armado, porque o morador carrega uma vassoura, um pedaço de cano ou uma esteira enrolada, fornece a categoria que justifica a força letal a uma pessoa que não a preenche. A taxa em que um detector classifica um objeto comum portado como arma é, portanto, a quantidade que importa eticamente: a Seção 5.4 a mede, sinteticamente, e a Seção 6.4 a lê como a forma concreta do dano de uso dual.

4. Materiais e Métodos

4.1 Desenho da pesquisa, ética e posicionalidade

Este é um estudo computacional experimental em duas partes: uma caracterização do alvo aéreo sem qualquer detector (Seção 4.4) e detectores treinados apenas com imagens sintéticas, avaliados contra um teto treinado com imagens reais onde existe um benchmark público e sobre quadros sintéticos reservados onde não existe. Quatro restrições foram fixadas antes de qualquer corpus ser gerado: nenhuma imagem, geometria ou coordenada em nível de endereço do Jacarezinho entra no gerador, nos corpora ou em qualquer medição; os únicos dados reais são dois benchmarks públicos; quaisquer dados de campo futuros exigiriam uma revisão ética independente e um processo de engajamento comunitário externo à instituição policial; e tudo o que aqui se produz é uma medição sobre imagens sintéticas, nunca uma ferramenta operacional validada. A síntese é a base ética, pois um morador a quem se pedisse consentimento para fotografia aérea feita pela instituição que conduz as operações da Seção 3.1, ou para ela, não pode recusar livremente nem prever o uso da imagem; ela não resolve o uso dual, e o estudo não divulga nem corpora nem pesos (Seção 4.8).

4.2 Gerador de cenas sintéticas

As cenas são geradas proceduralmente no Blender 5.2 (Blender Foundation, 2026), em modo headless com semente determinística, e renderizadas com seu path tracer Cycles; materiais e árvores são de domínio público (Poly Haven, n.d.), as figuras humanas vêm dos ativos CC0 do MakeHuman por meio do MPFB (MakeHuman Community, 2026), e toda a demais geometria é autorada pelo gerador. Nenhuma imagem ou geometria do território entra nele, de modo que o corpus se situa, por construção, no lado genérico da ablação de Liao et al. (2026), um custo que a Seção 4.1 nos impede de medir.

4.2.1 Traçado do assentamento

O traçado tem três estágios: parcelamento, uma partição binária recursiva do núcleo construído em que a maioria das moradias é contígua (o intervalo entre lotes é zero com probabilidade 0.82, de 0.5 a 1.2 m, a viela ou beco, com 0.12, e mais largo com 0.06); orientação, uma divisão de Voronoi do núcleo em subdistritos com orientações independentes, cada lote rotacionado em até 0.17 radianos e cada vértice passado por uma deformação suave de domínio; e acreção vertical, em que o pavimento superior da maioria das moradias de dois ou mais andares é menor e deslocado para um dos limites, e os telhados carregam caixas d'água, varais, caixas de escada, antenas parabólicas, chapas de cobertura, entulho e vergalhões expostos. Seis assentamentos diferem em relevo, cobertura florestal, um corredor através do núcleo, a paleta de telhados e fachadas, a distribuição de pavimentos e a proporção de lotes vagos; o assentamento 1 é o de todo corpus de assentamento único.

4.2.2 Figuras humanas, armas e objetos confundíveis

Cada execução constrói um conjunto de seis malhas com esqueleto (rigged) e vestidas com o MPFB, variadas por corpo em sexo, idade, constituição física, pele, cabelo e vestuário e por instância em cor do vestuário, escala (0.92 a 1.08), direção e pose; 45 por cento ficam sobre lajes de telhado (75 por cento no corpus de 35 m e seus derivados), o restante em vielas, 12 a 34 por quadro nos corpora de treino e 10 a 26 no corpus piloto. Três classes são anotadas: armado (portando uma arma de fogo), desarmado sem portar nada e desarmado portando um objeto alongado. Cinco armas de fogo são construídas a partir de caixas e cilindros, dois fuzis (comprimentos registrados de 0.92 e 0.94 m), uma carabina (0.62 m), uma espingarda (1.05 m) e uma pistola (0.20 m); contra elas se colocam nove objetos que vão de 0.88 a 2.5 m: vassouras, rodos, cano plástico, vergalhão, tábuas, guarda-chuvas fechados, enxadas, esteiras enroladas e mangueira. Ambos se valem de uma única paleta de 11 materiais, cinco compartilhados e seis apenas nos objetos, e ambos são portados nas mesmas quatro poses (segurado à frente, ao lado, a tiracolo nas costas, enquanto caminha), com uma orientação fixada por pose; um objeto mais longo que 1.15 m, comprimento que nenhuma arma alcança pelo valor registrado (medida na malha, a espingarda chega a 1.17 m, Seção 5.1), é reangulado para repousar sobre o ombro ou apontar para o chão. Um detector pode, portanto, separar as classes pelo comprimento, pelos materiais que só os objetos têm ou pelo ângulo de porte; o teste de porte como arma do Experimento C neutraliza o terceiro, apenas no corpus original de 75 m, e o controle pareado por comprimento, o primeiro. No corpus de 35 m e seus derivados o objeto assume uma distribuição mais realista de poses enquanto a arma mantém a original, de modo que ali a pose de porte é uma quarta pista. Um fuzil de 1.10 m e uma submetralhadora compacta de 0.55 m servem apenas ao teste de arma não vista, e o corpus piloto e o corpus principal carregam uma biblioteca anterior, menor.

4.2.3 Regimes de iluminação

Seis regimes de iluminação fixam, cada um, irradiância e cor solares, o diâmetro angular do disco solar, uma faixa de elevação solar, preenchimento do céu, espalhamento, aerossóis e exposição: sol forte (elevação de 46 a 74 graus, disco de 0.6 grau), sol baixo (9 a 25, 0.9), céu encoberto (30 a 70, 24), céu fortemente encoberto (28 a 66, 38), bruma (22 a 52, 7) e chuva (24 a 60, 32); acima de um disco de aproximadamente 20 graus a sombra projetada efetivamente desaparece, e nenhuma gota de chuva ou superfície molhada é renderizada. Cada corpus percorre os seis regimes em ordem, e o regime de cada imagem é registrado.

4.2.4 Modelo de câmera e geometrias de aquisição

A câmera virtual reproduz uma carga útil de UAV disponível comercialmente em seu ajuste grande-angular, a DJI Zenmuse Z30, um sensor de 1/2.8 polegada com 2.13 megapixels efetivos que grava a 1920 por 1080 atrás de um zoom óptico de 30 vezes de 4.3 a 129 mm (DJI, 2019): uma lente de 4.3 mm sobre um sensor de 5.37 mm, um campo de visão horizontal de 63.96 graus em 16:9 e uma largura no solo de 1.2488 vezes a altitude em nadir. A câmera nadir aponta para baixo a até 3.5 graus da vertical, a uma altitude comandada de 150, 75 ou 35 m, com um jitter por imagem de até 6 m (3 m a 35 m, 13 m no gêmeo a 150 m); a câmera oblíqua voa a 120 m com um jitter de até 36 m, a uma inclinação sorteada por imagem entre 26 e

52 graus a partir da vertical (S-oblique) ou entre 45 e 56 (S-oblique-six). A Figura 1 mostra o mesmo assentamento sob ambas, e a Tabela 1 fornece a distância de amostragem do solo (GSD) e a pegada por altitude e tamanho de renderização. Os rótulos de altitude deste artigo, 150, 75 e 35 m, denotam a GSD que esta câmera alcança naquela altitude quando renderizada a 3840 por 2160, 4.88, 2.44 e 1.14 cm por pixel; a mesma GSD é alcançável de altitude maior por meio de zoom, ao custo da pegada (Seção 6.2). O renderizador não simula ruído de sensor, desfoque de movimento, profundidade de campo, rolling shutter, aberração cromática, vinhetagem ou distorção de lente; os quadros são PNG sem perdas, e os ladrilhos de treino são recodificados uma vez como JPEG com qualidade 92.

Tabela 1. GSD e pegada da câmera do gerador por altitude e tamanho de renderização, em nadir, na altitude comandada; a altitude média realizada de cada corpus difere dela em cerca de 1 por cento ou menos. A linha oblíqua fornece o valor nadir nominal no centro do quadro. O negrito marca as GSDs que os rótulos de altitude do artigo denotam.

Altitude (m)	Pegada (m × m)	Renderização (px)	GSD (cm/px)
35	43.7 × 24.6	1920 × 1080	2.28
35	43.7 × 24.6	3840 × 2160	**1.14**
75	93.7 × 52.7	1920 × 1080	4.88
75	93.7 × 52.7	3840 × 2160	**2.44**
120, predefinição oblíqua	149.9 × 84.3 (nominal)	3840 × 2160	3.90 (nominal)
150	187.3 × 105.4	1920 × 1080	9.76
150	187.3 × 105.4	3840 × 2160	**4.88**

4.2.5 Anotação automática

Para cada figura, o gerador projeta uma subamostra dos vértices do corpo e da roupa e todos os vértices de qualquer item portado no espaço da imagem e toma a extensão alinhada aos eixos, recortada ao quadro: a caixa é amodal dentro do quadro, como no benchmark, inclui o item portado e assume sua classe. Instâncias com fração visível abaixo de 0.35 sob 14 raios lançados a partir da câmera, fora do quadro ou com um lado recortado abaixo de 0.002 do quadro são descartadas.



Figura 1. O mesmo assentamento sob as duas geometrias de câmera comparadas no Experimento A: verticalmente para baixo a partir de 150 m, a aquisição de referência deste estudo, e oblíqua a partir de cerca de 120 m, mais próxima da do benchmark. Abaixo de cada quadro, quatro figuras sem portar nada, ampliadas ao mesmo tamanho sem suavização: a planta de uma figura vista de cima, uma figura em pé com seus membros vista pela câmera oblíqua.

4.3 Corpora sintéticos e dados reais

A Tabela 2 lista todos os corpora. Os corpora de treino são pareados por quadros, 180 de classe única e 200 de três classes; as contagens de instâncias diferem conforme a proporção de figuras posicionadas que sobrevivem ao filtro da Seção 4.2.5, e o S-oblique-six carrega apenas figuras sem portar nada. Os dados reais são o VisDrone-DET, com suas categorias pedestrian e people fundidas em uma única classe pessoa. Sua partição de validação de 548 imagens é o conjunto de teste de todo modelo de classe única, e nenhuma imagem dela entra no treino ou na seleção. R treina com 1,106 imagens sorteadas ao acaso da partição de treino (18,858 pessoas) e seleciona seu checkpoint em outras 265 imagens de treino disjuntas de ambas (Seção 4.5); três fatias adicionais servem ao Experimento B: 5 por cento (324 imagens), 10 por cento (647, contendo a primeira) e uma fatia de seleção disjunta de 324. O segundo conjunto de teste real é o HERIDAL (Pyrrö, Naseri, & Jung, 2021), na versão distribuída por Pyrrö (2021), a um valor estimado de 1.5 a 2.4 cm por pixel, o único conjunto público encontrado com caixas de pessoas em terra e vista nadir declarada; todas as 1,647 imagens anotadas, com 3,229 pessoas, servem apenas à avaliação zero-shot. Os quadros reservados (Tabela 2) foram renderizados depois que os modelos que eles testam haviam sido treinados, continuando a semente de seu corpus nos mesmos índices de quadro ao longo do corpus de 35 m e seus gêmeos; os dois conjuntos de 75 m são uma nova realização do assentamento, um carregando os dois modelos de arma de fogo não vistos em metade das armas de fogo e o outro renderizando-o novamente com todo objeto confundível portado exatamente como uma arma.

Tabela 2. Todos os corpora do estudo, exceto os três corpora de treino derivados listados na Tabela 3 (o corpus somente de sol forte e as duas réplicas de semente de assentamento do S-oblique-six), os subconjuntos aninhados de seus quadros de treino e os dois corpora de treino pareados por comprimento da Seção 4.6. Linhas sintéticas: câmera, altitude comandada e GSD nominal, tamanho de renderização, quadros por partição, ladrilhos de treino por partição e instâncias anotadas por classe nos quadros inteiros (armado / desarmado / portando um objeto confundível). Linhas reais: imagens e instâncias de

pessoa dos subconjuntos do VisDrone-DET e do HERIDAL. Os quadros de teste reservados foram renderizados após o treino e não foram usados nem para treino nem para seleção de checkpoint. A entrada n.a. marca uma classe ou uma coluna que não se aplica àquela linha.

Corpus	Câmera, altitude, GSD (cm/px)	Renderização (px)	Quadros ou imagens, treino / val	Ladrilhos, treino / val	Instâncias, treino	Instâncias, val
Corpus piloto	nadir, 150 m, 9.76	1920 × 1080	40 / 8	274 / 61	292 / 273 / n.a.	55 / 64 / n.a.
S-nadir-150 (corpus principal)	nadir, 150 m, 4.88	3840 × 2160	149 / 31	1,106 / 225	1,331 / 1,328 / n.a.	278 / 288 / n.a.
S-nadir-150-six	nadir, 150 m, 4.88; 6 assentamentos	3840 × 2160	156 / 24	1,135 / 174	1,424 / 1,368 / n.a.	203 / 233 / n.a.
S-oblique	oblíqua 26 a 52°, 120 m, 3.90 nominal	3840 × 2160	155 / 25	968 / 136	839 / 841 / n.a.	113 / 119 / n.a.
S-oblique-six	oblíqua 45 a 56°, 120 m, 3.90 nominal; 6 assentamentos	3840 × 2160	152 / 28	890 / 144	n.a. / 1,325 / n.a.	n.a. / 196 / n.a.
S-nadir-75	nadir, 75 m, 2.44	3840 × 2160	173 / 27	1,316 / 202	816 / 820 / 846	117 / 153 / 135
S-nadir-35	nadir, 35 m, 1.14	3840 × 2160	165 / 35	1,166 / 242	640 / 587 / 619	137 / 119 / 121
Gêmeo a 75 m	nadir, 75 m, 2.44	3840 × 2160	176 / 24	1,287 / 176	650 / 638 / 701	85 / 92 / 91
Gêmeo a 150 m	nadir, 150 m, 4.88	3840 × 2160	173 / 27	1,215 / 180	692 / 619 / 640	92 / 104 / 101
Reservado: novos quadros, 35 m	nadir, 35 m, 1.14	3840 × 2160	0 / 80	não ladrilhado	n.a.	346 / 315 / 292
Reservado: novos quadros, gêmeo a 75 m	nadir, 75 m, 2.44	3840 × 2160	0 / 80	não ladrilhado	n.a.	257 / 292 / 288
Reservado: novos quadros, gêmeo a 150 m	nadir, 150 m, 4.88	3840 × 2160	0 / 80	não ladrilhado	n.a.	324 / 278 / 314
Reservado: teste de arma não vista	nadir, 75 m, 2.44; nova realização	3840 × 2160	0 / 50	não ladrilhado	n.a.	256 / 222 / 230
Reservado: nova renderização com porte como arma	nadir, 75 m, 2.44; nova realização	3840 × 2160	0 / 50	não ladrilhado	n.a.	256 / 222 / 231
Reservado: teste por regime	nadir, 150 m, 4.88	3840 × 2160	0 / 120	0 / 885	n.a.	1,085 / 1,119 / n.a.
VisDrone-DET treino, completo	real	misto; 1400 × 1050 mais comum	6,471 / n.a.	n.a.	106,396 pessoas	n.a.
VisDrone-DET val (conjunto de teste)	real	misto; 408 de 548 a 1360 × 765	n.a. / 548	n.a.	n.a.	13,969 pessoas
Subconjunto R do treino	real	como o treino	1,106 / n.a.	n.a.	18,858 pessoas	n.a.
Fatia de 5 por cento do treino	real	como o treino	324 / n.a.	n.a.	5,883 pessoas	n.a.
Fatia de 10 por cento (contém a fatia de 5 por cento)	real	como o treino	647 / n.a.	n.a.	11,091 pessoas	n.a.
Fatia de seleção (disjunta de ambas)	real	como o treino	n.a. / 324	n.a.	n.a.	5,886 pessoas
HERIDAL, todas as imagens anotadas (segundo conjunto de teste)	real, nadir, 40 a 65 m, 1.5 a 2.4 estimado	4000 × 3000	n.a. / 1,647	n.a.	n.a.	3,229 pessoas

4.4 Caracterização do alvo sem modelo

Três propriedades do alvo são medidas apenas a partir das anotações e dos pixels renderizados: tamanho por GSD, como as dimensões medianas da caixa anotada em resolução nativa e a proporção de instâncias cujo lado menor fica abaixo de 8 pixels, um stride do mapa de características mais fino do detector; forma por inclinação da câmera, como a razão altura-largura da caixa, com as figuras sem portar nada medidas separadamente porque um item portado alarga a caixa; e contraste por regime, no corpus piloto (48 quadros, 8 por regime), como a luminância média dentro da caixa contra um anel de 6 pixels ao seu redor, dividida pelo desvio padrão desse anel. Uma quarta medição pergunta se recortes das três classes se separam em cada GSD sem qualquer detector treinado nos corpora: toda figura anotada dos quatro corpora de três classes é recortada com margem de 25 por cento, embutida pelo backbone congelado do detector pré-treinado no COCO e classificada por centroide mais próximo sob validação cruzada em 5 dobras, avaliada pelas taxas da Seção 4.7 e pela área sob a curva característica de operação do receptor (AUC).

4.5 Detector e protocolo de treino

O detector é o YOLO11s, o membro pequeno da família Ultralytics YOLO11 (Jocher & Qiu, 2024), treinado em uma única GPU de consumo com 6 GB, a partir de pesos pré-treinados no COCO, um corpus genérico de detecção com 80 classes (Lin et al., 2014), exceto pelos modelos de ajuste fino com início sintético, que partem do S-oblique-six. O treino sintético opera sobre ladrilhos de 1280 pixels recortados em escala nativa com 20 por cento de sobreposição, nunca sobre quadros reduzidos, o que levaria a largura mediana da instância a 150 m abaixo de um stride; os modelos de dados reais treinam com imagens inteiras do benchmark redimensionadas para 1280 pixels no lado maior, e os modelos conjuntos com ambos. As configurações compartilhadas estão na nota da Tabela 3, e cada quadro sintético vai para a validação com probabilidade 0.15, por quadro, nunca por ladrilho. O melhor checkpoint por mAP50-95 (Seção 4.7) é mantido em uma partição de seleção: os quadros de validação de seu próprio corpus para um modelo sintético, de modo que o benchmark nunca entra na seleção de um modelo de classe única; a fatia de seleção para os modelos de ajuste fino e conjuntos; e, para R, as 265 imagens da Seção 4.3, ao longo de 60 épocas sem parada antecipada. R foi inicialmente selecionado no próprio conjunto de teste; o teto relatado remove esse viés (Seção 5.2), e R ainda treina com o cronograma compartilhado não ajustado, de modo que é um teto para o protocolo, não para o benchmark (Seção 6.5).

4.6 Desenho experimental

Quatro experimentos respondem às questões de pesquisa; a Figura 2 mostra como os corpora, os modelos e os dois tipos de conjunto de teste se conectam, e a Tabela 3 lista os modelos.

Experimento A (transferência zero-shot; RQ1). R, S-nadir-150, S-nadir-150-six, S-oblique e S-oblique-six são avaliados no mesmo conjunto de teste real, e cada escore sintético é reportado como razão em relação a R. S-oblique altera apenas a câmera, de modo que a diferença é lida como a contribuição da geometria de captura; S-oblique-six acrescenta seis assentamentos e uma faixa de inclinação pareada com a partição de treino do benchmark. Três verificações o acompanham: uma avaliação pareada por escala com tamanho de entrada de 1,024 pixels, fixada de antemão; se R desempenha próximo do acaso; e a avaliação zero-shot dos cinco modelos no HERIDAL a 1,152 pixels, também fixada de antemão. Uma quarta verificação retreina S-nadir-150 e S-oblique-six em ladrilhos de treino dos quais três quartos carregam ruído gaussiano dependente do sinal (desvio padrão de 0.4 a 1.8 por cento da escala plena), desfoque de 0.3 a 1.2 pixels e compressão JPEG com qualidade de 50 a 90, com os ladrilhos de validação intocados, e os avalia zero-shot em ambos os benchmarks; uma diferença pareada contra o modelo limpo cujo intervalo exclui zero é lida como artefatos de sensor explicando parte da lacuna naquele benchmark.

Experimento B (dados reais limitados; RQ2). Em cada fatia, F-synthetic (a partir de S-oblique-six) e F-generic (a partir de COCO) treinam por 30 épocas, primeiro sob o mesmo cronograma de treino não ajustado e depois sob uma grade de quatro cronogramas de treino que cruzam backbone treinável ou congelado com taxa de aprendizado de 0.002 ou 0.0002; cada

Tabela 3. Os modelos do protocolo, seus dados de treino e o que cada um estabelece.

Modelo	Dados de treino	O que estabelece
R	1,106 imagens reais sorteadas ao acaso de VisDrone-DET train	o teto no conjunto de teste a volume pareado
S-nadir-150	o corpus principal: 1 assentamento, nadir a 150 m, 6 regimes	o método na aquisição de referência
S-nadir-150-six	as mesmas configurações em 6 assentamentos	se a variedade de assentamentos é um termo da lacuna
S-oblique	o mesmo assentamento e as mesmas configurações, câmera oblíqua	se a falha é atribuível à síntese ou à geometria de captura
S-oblique-six	6 assentamentos, inclinação de 45 a 56 graus, figuras que nada carregam	o modelo sintético deste artigo, o braço sintético com o maior mAP50 zero-shot no conjunto de teste real
S-oblique-six com os assentamentos sorteados de novo (duas réplicas); com 30 a 120 quadros	as mesmas configurações com os assentamentos sorteados de novo; subconjuntos aninhados de seus 152 quadros de treino	a dispersão devida à cena; se o número de quadros é operante
F-synthetic, F-generic	5 ou 10% de VisDrone-DET train, a partir de S-oblique-six ou de COCO	quanto vale o pré-treino sintético quando existem alguns dados reais
F-joint	os 890 ladrilhos de treino de S-oblique-six com as mesmas imagens reais, a partir de COCO	quanto vale o corpus misturado a dados reais
F-synthetic, F-generic sob 3 cronogramas de treino adicionais	como acima, backbone congelado, taxa de aprendizado dez vezes menor, ou ambos	se o custo do início sintético pertence ao cronograma de treino
Modelo apenas de sol forte	180 quadros com as configurações do corpus principal apenas sob sol forte	se um déficit sob sol forte pertence ao regime ou à sua parcela no treino
S-nadir-75	200 quadros a 75 m, 3 classes	se a distinção entre armado e desarmado é resolúvel
S-nadir-35 e seus gêmeos a 75 e 150 m	200 quadros a 35 m com poses de porte realistas; o mesmo corpus renderizado a 75 e a 150 m	se a resolução ou a pose de porte conduz a confusão; se a distinção é mensurável a 150 m

Nota. Configurações de treino compartilhadas: entrada de 1280 pixels; batch 6; AdamW com taxa de aprendizado inicial de 0.002 (0.001429 para os modelos de três classes) e decaimento linear; mosaico, espelhamento horizontal, rotação de até 10 graus, ganho de escala 0.4 e variação de cor como aumento de dados; 60 épocas para os modelos sintéticos, 30 para os modelos de ajuste fino e conjuntos, 120 com paciência 30 para o gêmeo a 150 m e os dois controles de orçamento, paciência 15 nos demais casos; inferência com confiança 0.001 e supressão de não máximos a IoU 0.7 (padrões, não ajustados) para o mAP, e taxas de três classes a confiança 0.25 em quadros inteiros; semente de treino 0 com operações determinísticas, sementes 1 e 2 para os modelos repetidos.

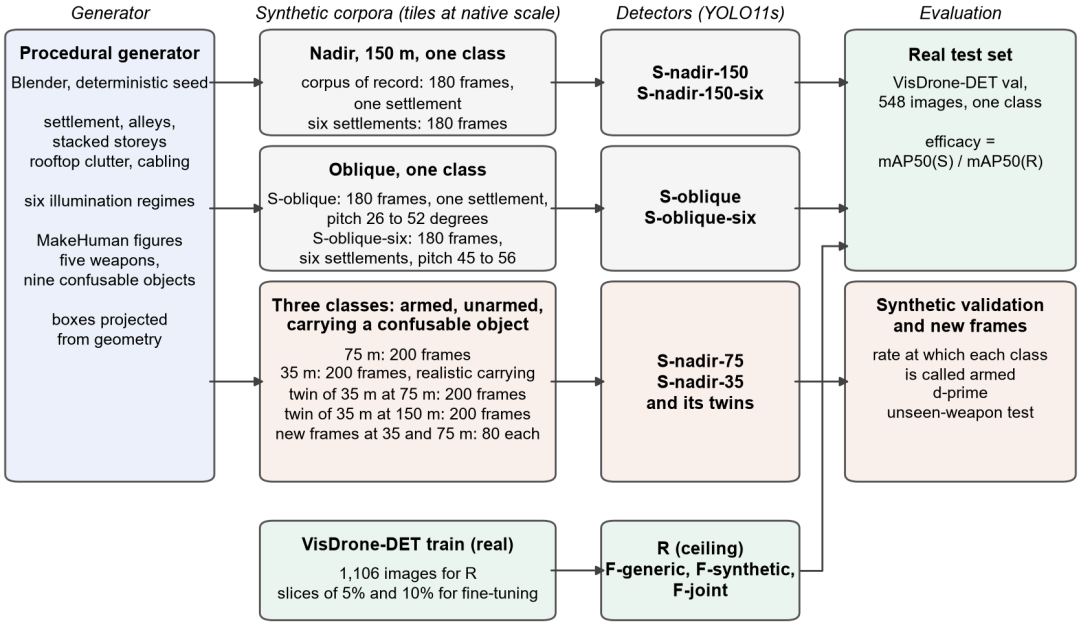


Figura 2. O desenho dos experimentos. Um único gerador procedural produz todos os corpora sintéticos. Os modelos de classe única são avaliados no benchmark real contra o teto R; os modelos de três classes, na partição de seleção do próprio corpus e em quadros reservados renderizados após o treino; os modelos de ajuste fino e conjuntos, que usam fatias da partição de treino do benchmark e selecionam em uma fatia disjunta, no mesmo conjunto de teste real. O benchmark nadir, usado apenas para a avaliação zero-shot dos modelos de classe única, não está desenhado.

ponto de partida mantém a célula com o maior mAP50-95 na fatia de seleção, nunca no conjunto de teste. F-joint parte de COCO e treina por 30 épocas nos 890 ladrilhos de treino de S-oblique-six com as mesmas 324 ou 647 imagens reais. A quantidade de interesse é a diferença, em cada volume, entre o modelo que usa o corpus sintético e F-generic.

Experimento C (a distinção entre armado e desarmado a distinção entre armado e desarmado por GSD; RQ3). S-nadir-75 é avaliado, como três classes, em sua partição de seleção e nos dois conjuntos reservados a 75 m: o teste de arma não vista compara a revocação nas cinco armas de fogo de treino com a revocação nas duas não vistas nos mesmos 50 quadros, e o teste de porte como arma pareia os 227 objetos confundíveis caixa a caixa entre as duas renderizações e compara a taxa com que são classificados como armados quando portados normalmente e quando portados nas poses e nos ângulos das armas. S-nadir-35 e seus gêmeos a 75 e 150 m, idênticos exceto na altitude, separam resolução de pose de porte: cada um é avaliado em 80 quadros reservados que compartilham seus índices entre os corpora, os dois primeiros em três sementes e a IoU 0.50, 0.60 e 0.75, e o gêmeo a 150 m após um segundo treino de 120 épocas com paciência de 30. Seguem dois controles, cada um fixado de antemão: um controle de orçamento retreina o modelo de 35 m e seu gêmeo a 75 m sob esse cronograma de treino mais longo e os avalia nos mesmos quadros, e um controle pareado por comprimento renderiza de novo os gêmeos a 75 e 150 m com cada objeto confundível escalado apenas ao longo de seu comprimento para entre 0.62 e 1.05 m, os comprimentos registrados das quatro armas de fogo longas, com largura, altura e material inalterados; o modelo treinado em cada um é avaliado em 80 novos quadros do mesmo tipo, e cada modelo original nos quadros do outro.

Experimento D (iluminação). S-nadir-150 é avaliado por regime nos 120 quadros reservados de seu assentamento, como mAP50 nos ladrilhos de cada regime e revocação a confiança 0.25 em quadros inteiros; um modelo treinado apenas sob sol forte é comparado a ele em revocação sob sol forte (D-i, descritivo) e contra seu valor sob céu encoberto (D-ii, o que decide). Se o intervalo de D-ii estiver inteiramente abaixo de zero e o mAP50 do especialista sob sol forte permanecer abaixo desse valor sob céu encoberto, o déficit pertence ao regime; caso contrário, à parcela de sol forte no treino.

Confirmatório contra exploratório. O protocolo cresceu em etapas. Fixados antes da primeira execução: R, S-nadir-150, S-oblique e S-nadir-75, e a razão de eficácia em relação a R no benchmark urbano. Todo modelo e teste posterior foi acrescentado depois que os resultados anteriores eram conhecidos, cada um com seu critério registrado antes da execução e enunciado na Seção 5 junto ao resultado que decide. Uma regra foi alterada depois que seu resultado era conhecido, e é declarada como tal: conforme escrita originalmente, um intervalo de d′ a 150 m que excluísse zero deveria ser lido como atalho, sob o argumento de que a forma de uma arma de fogo se perde nessa GSD; aplicada em outubro, ela leu o gêmeo a 150 m como atalho, e foi substituída em novembro, antes que o controle pareado por comprimento tivesse sido executado, porque nenhum desfecho poderia tê-la reprovado. A hipótese fixada em seu lugar, e testada na Seção 5.4, é a de que a separação a 150 m repousa sobre o comprimento: se o intervalo de d′ do modelo pareado por comprimento contra objetos inclui zero, a separação nessa GSD dependia do comprimento; se o exclui, forma ou material sobrevive sem ele, e a queda em relação ao modelo original mede quanto da separação o comprimento explicava. R também foi re-selecionado, depois que os resultados eram conhecidos, em uma fatia fora do conjunto de

teste, e toda eficácia foi recomputada a partir dele (Seção 4.5). Ainda em execução quando esta versão foi escrita, cada um com seu critério fixado de antemão: sementes adicionais para os modelos treinados uma única vez, entre eles os controles e os modelos degradados; o teto treinado em toda a partição de treino; o especialista em sol forte contra um modelo treinado em todos os regimes exceto sol forte; e a arma de fogo segurada na mão em vez de apoiada contra o punho. Nenhuma taxa aceitável de falso alarme foi fixada para RQ3: que taxa de moradores portando um objeto doméstico marcados como armados é tolerável é uma decisão normativa da autoridade pública e do controle judicial, não uma constante de engenharia (Seção 6.4).

4.7 Métricas, análise estatística e critérios pré-especificados

A detecção é avaliada por mAP50 e por mAP50-95, a mesma quantidade tomada em média sobre limiares de IoU de 0.50 a 0.95, a medida de aptidão pela qual todo checkpoint é selecionado. A eficácia é o mAP50 de um modelo sintético dividido pelo de R no mesmo conjunto de teste. Os modelos de três classes são avaliados em quadros inteiros em escala nativa a confiança 0.25: as predições são pareadas uma a uma com as figuras anotadas a IoU 0.50 sem consideração de classe, cada figura recebe a classe de sua predição de maior sobreposição, e uma figura não pareada conta como não classificada como armada, o que torna cada uma das três taxas a seguir um limite inferior: a revocação de armados, a taxa com que um objeto confundível é classificado como armado (a taxa de objetos) e a taxa com que uma pessoa desarmada que nada carrega é classificada como armada; a quarta grandeza reportada é a precisão da classe armada. A revocação de armados e a taxa de cada outra classe dão d′, com a correção log-linear de Hautus (1995). O limiar de confiança é varrido de 0.05 a 0.95. Dez modelos foram treinados três vezes (S-nadir-150, S-oblique, S-oblique-six e seus subconjuntos aninhados de 30 e 120 quadros de treino, F-synthetic e F-generic na fatia de 5 por cento, F-generic com a taxa de aprendizado menor nessa fatia, S-nadir-35 e seu gêmeo a 75 m), todos os demais uma vez. Os intervalos são intervalos percentílicos de 95 por cento a partir de 1,000 reamostragens de imagens do benchmark ou de quadros sintéticos (2,000 para a revocação por regime do Experimento D), com diferenças pareadas e razões nas mesmas reamostragens. Uma diferença é resolúvel se as faixas dos dois modelos ao longo de suas três sementes não se sobrepõem (leitura a) ou se o intervalo de 95 por cento da diferença pareada exclui zero (leitura b); uma diferença relativa de 30 por cento do menor valor é reportada descritivamente (leitura c), e uma diferença que não passa nem em (a) nem em (b) é reportada como não resolúvel.

4.8 Reprodutibilidade

Toda imagem gerada registra sua semente, regime, altitude comandada e realizada e, nos corpora posteriores, a inclinação da câmera, de modo que o assentamento, a câmera e a iluminação de toda imagem reportada são reproduzíveis pelos autores; as figuras são reproduzíveis apenas nos corpora renderizados depois que o gerador de figuras passou a sortear de um fluxo com semente, e nos três renderizados antes que esse defeito fosse encontrado (o corpus piloto, o corpus principal e S-nadir-75) seu posicionamento e aparência não podem ser regenerados exatamente. O treino é determinístico sob semente fixa. O gerador procedural de cenas e seu código estão disponíveis junto aos autores mediante solicitação direta; os corpora e os pesos treinados não são divulgados. O que um leitor pode verificar sem eles é cada benchmark, a especificação publicada da câmera de referência e todo parâmetro das Seções 4.2 a 4.7, o que basta para reimplementar o protocolo e aproximar o gerador, sendo todo ativo de domínio público.

5. Resultados

A Tabela 4 reúne todos os modelos com seu conjunto de teste e seu valor principal; a Seção 5.1 reporta a caracterização independente de modelo e as Seções 5.2 a 5.5, os Experimentos A a D. Toda verificação fixada de antemão foi executada: o teto se manteve, longe do acaso; a verificação pareada por escala deslocou o escore nadir em um quarto do valor do protocolo, abaixo da metade fixada como sinal de confundimento; e nenhuma comparação pré-especificada se inverteu sob a regra oficial do toolkit do VisDrone para regiões ignoradas ou a IoU 0.60 e 0.75, embora uma tenha empatado a 0.75 (Tabela 10).

Tabela 4. Resultados em resumo: mAP50 em VisDrone-DET val com intervalos de 95 por cento por reamostragem das 548 imagens de teste, e eficácia em relação a R nas mesmas reamostragens; onde um modelo foi treinado três vezes, a média das três execuções com seu intervalo e, para os modelos zero-shot, a melhor execução. As linhas HERIDAL dão o benchmark nadir no tamanho de entrada pareado. Os modelos de três classes trazem seu mAP50 de três classes e a taxa de objetos a confiança 0.25 em sua partição de seleção e em quadros reservados renderizados após o treino.

Modelo	Dados de treino (imagens reais)	Conjunto de teste	mAP50 (intervalo de 95%)	Eficácia (intervalo de 95%)
R, checkpoint selecionado fora do conjunto de teste	1,106 imagens de VisDrone-DET train (1,106)	VisDrone-DET val	0.6224 (0.6069 a 0.6397)	teto; 0.6311 se selecionado no conjunto de teste, +0.0087 (+0.0035 a +0.0136)
S-nadir-150, média de 3 sementes (melhor execução)	180 quadros, 1 assentamento, nadir, 4.88 cm/px (0)	VisDrone-DET val	0.0136 (0.0120 a 0.0160); melhor 0.0198	2.2% (1.9 a 2.6); melhor 3.2%
S-nadir-150-six	180 quadros, 6 assentamentos, nadir, 4.88 cm/px (0)	VisDrone-DET val	0.0190 (0.0142 a 0.0211)	3.1% (2.3 a 3.4)
S-oblique, média de 3 sementes (melhor execução)	180 quadros, 1 assentamento, oblíqua, 3.90 cm/px nominal (0)	VisDrone-DET val	0.0555 (0.0502 a 0.0614); melhor 0.0614	8.9% (8.2 a 9.7); melhor 9.9%
S-oblique-six, média de 3 sementes (melhor execução)	180 quadros, 6 assentamentos, inclinação de 45 a 56 graus (0)	VisDrone-DET val	0.0966 (0.0896 a 0.1048); melhor 0.1055	15.5% (14.6 a 16.7); melhor 16.9%

F-synthetic, 5% (média de 3 sementes) e 10% (primeira semente)	a partir de S-oblique-six (324 e 647)	VisDrone-DET val	0.4529 (0.4373 a 0.4696); 0.5095 (0.4935 a 0.5264)	72.8% (71.2 a 74.0); 81.8% (80.6 a 83.0)
F-generic, 5% (média de 3 sementes) e 10% (primeira semente)	a partir dos pesos COCO (324 e 647)	VisDrone-DET val	0.5245 (0.5075 a 0.5424); 0.5709 (0.5535 a 0.5883)	84.3% (83.1 a 85.3); 91.7% (90.6 a 92.6)
F-generic, taxa de aprendizado menor (escolhida na fatia de seleção), 5 e 10%	a partir dos pesos COCO (324 e 647)	VisDrone-DET val	0.5897 (0.5748 a 0.6073), média de 3 sementes; 0.6224 (0.6072 a 0.6396)	94.8% (93.6 a 95.9); 100.0% (98.8 a 101.3)
F-joint, 5 e 10%	pesos COCO, 890 ladrilhos sintéticos e as imagens reais (324 e 647)	VisDrone-DET val	0.4607 (0.4444 a 0.4789); 0.5428 (0.5259 a 0.5610)	74.0% (72.6 a 75.5); 87.2% (86.0 a 88.3)
R no benchmark nadir, checkpoint selecionado fora do conjunto de teste	como acima (1,106)	HERIDAL, 1,647 imagens	0.2927 (0.2618 a 0.3247)	teto; 0.3185 se selecionado no conjunto de teste urbano, +0.0258 (+0.0113 a +0.0421)
S-nadir-150 no benchmark nadir, média de 3 sementes	como acima (0)	HERIDAL	0.1997 (0.1713 a 0.2306)	68.2% (59.0 a 78.9)
S-oblique no benchmark nadir, média de 3 sementes	como acima (0)	HERIDAL	0.1341 (0.1149 a 0.1555)	45.8% (40.6 a 52.6)
S-nadir-75	200 quadros, 3 classes, 2.44 cm/px (0)	partição de seleção, 27 quadros; reservados, 50	0.579; taxa de objetos 0.237; reservados 0.152	não se aplica
S-nadir-35	200 quadros, 3 classes, 1.14 cm/px (0)	partição de seleção, 35; reservados, 80	0.514; taxa de objetos 0.273; reservados 0.253	não se aplica
Gêmeo de S-nadir-35 a 75 m	o corpus de 35 m a 2.44 cm/px (0)	partição de seleção, 24; reservados, 80	0.508; taxa de objetos 0.165; reservados 0.125	não se aplica
Gêmeo de S-nadir-35 a 150 m, treinado por mais tempo	o corpus de 35 m a 4.88 cm/px (0)	partição de seleção, 27; reservados, 80	0.388; taxa de objetos 0.178; reservados 0.245	não se aplica
S-nadir-35 e seu gêmeo a 75 m, treinados por mais tempo (controle de orçamento)	o corpus de 35 m a 1.14 e 2.44 cm/px (0)	partição de seleção, 35 e 24; reservados, 80	0.499 e 0.521; taxa de objetos 0.248 e 0.220; reservados 0.192 e 0.222	não se aplica
Gêmeo a 75 m, objetos com comprimento de arma de fogo (controle pareado por comprimento)	o gêmeo de 75 m com cada objeto de 0.62 a 1.05 m de comprimento (0)	partição de seleção, 28; reservados, 80	0.547; taxa de objetos 0.164; reservados 0.201	não se aplica
Gêmeo a 150 m, objetos com comprimento de arma de fogo, treinado por mais tempo	o gêmeo de 150 m com cada objeto de 0.62 a 1.05 m de comprimento (0)	partição de seleção, 20; reservados, 80	0.384; taxa de objetos 0.176; reservados 0.158	não se aplica

5.1 Caracterização do alvo: tamanho, forma e contraste

A GSD definiu o tamanho do alvo; a inclinação da câmera, sua forma; e o regime de iluminação, seu contraste contra a desordem visual local (Tabela 5). Reduzir a GSD à metade, de 9.76 para 4.88 cm por pixel, levou a mediana do lado maior de 10.1 para 20.6 pixels e a parcela de instâncias abaixo de um stride no lado menor de 66.9 para 0.8 por cento, contra 30.5 por cento no benchmark e 0.9 e 3.9 nos dois corpora oblíquos; em área, a instância sintética mediana a 4.88 cm por pixel (área mediana de 301 pixels quadrados) igualou a instância mediana do benchmark (300), e a 2.44 e 1.14 a instância mediana mediu 47.6 por 41.7 e 121.8 por 103.1 pixels. Os dois corpora nadir concordaram na razão altura-largura até a segunda casa decimal, 0.98, contra 1.95 e 2.20 nas duas partições do benchmark; no corpus oblíquo a razão subiu com a inclinação, de 1.28 entre 26 e 30 graus para 1.70 entre 50 e 52.

A arma é menor ainda. Medidos de ponta a ponta nas malhas (os fuzis e a espingarda excedem seus comprimentos registrados porque coronha e carregador ficam fora deles), os dois fuzis medem 1.07 m, a espingarda 1.17, a carabina 0.61 e a pistola 0.20, e nenhuma é mais larga que 0.05 m. A 4.88 cm por pixel um fuzil cobre, portanto, cerca de 22 pixels de comprimento e um de largura, a 2.44 cerca de 44 por 2 e a 1.14 cerca de 94 por 4; a pistola, 4 por 0.6, 8 por 1.2 e 17 por 2.6. A 150 m a arma de fogo mais larga do corpus tem um pixel de largura e a pistola mal chega a meio: o que sobrevive à GSD é o comprimento, não a forma. Essas são extensões da malha, não pegadas no quadro, que dependem de como a arma é portada.

No corpus piloto, o céu encoberto deu o maior contraste sobre a desordem visual local e o sol forte e a chuva, os dois menores, apenas a distância entre os extremos se aproximando de um desvio padrão. A Figura 3 mostra o que o detector recebe nas três GSDs do Experimento C. Sem nenhum detector treinado nos corpora, as três classes mal se separaram: uma regra de centroide mais próximo sobre características genéricas congeladas alcançou um d′ de 0.23 a 0.46 contra 0.67 a 0.90 para os detectores dos mesmos quatro corpora em suas partições de seleção, e a única estrutura presente opunha figuras que nada carregavam a figuras que carregavam qualquer coisa.

Tabela 5. Tamanho e forma do alvo por GSD e geometria da câmera, a partir dos rótulos de quadro inteiro em resolução nativa: dimensões medianas da caixa, razão altura-largura mediana, instâncias e parcela de instâncias cujo lado menor fica abaixo de um stride do detector (8 pixels). As linhas nadir tra-

zem a configuração do gerador (a até 3.5 graus da vertical); as linhas oblíquas registram a inclinação por imagem; o benchmark não registra geometria de aquisição.

Corpus e geometria	Altitude, GSD (cm/px)	Largura mediana	Altura mediana	h/w mediana	Instâncias	Lado menor abaixo de 8 px
Corpus piloto, nadir	150 m, 9.76	8.3 px	8.2 px	**0.98**	565	66.9%
Corpus principal, nadir	150 m, 4.88	17.6 px	17.5 px	**0.98**	3,225	0.8%
S-oblique, inclinação de 26 a 52 graus, um assentamento	120 m, 3.90 nominal	17.9 px	26.4 px	**1.46**	1,912	0.9%
S-oblique-six, inclinação de 45 a 56 graus, seis assentamentos, figuras que nada carregam	120 m, 3.90 nominal	13.3 px	25.2 px	**1.85**	1,521	3.9%
VisDrone-DET train, aquisição real	não registrada	13.0 px	24.0 px	**1.95**	106,396	n.r.
VisDrone-DET val, aquisição real	não registrada	12.0 px	25.0 px	**2.20**	13,969	30.5%

n.r.: não reportado.

5.2 Experimento A: transferência zero-shot para imagens reais

R alcançou mAP50 de 0.6224 (0.6069 a 0.6397) no conjunto de teste; selecionado no próprio conjunto de teste, marcou 0.6311, um viés de +0.0087 (+0.0035 a +0.0136) que o teto reportado remove. S-nadir-150 marcou 0.7915 em sua própria partição de validação e uma média de 0.0136 (0.0120 a 0.0160) no benchmark ao longo de três sementes, uma eficácia de 2.2 por cento (1.9 a 2.6). Seis assentamentos em lugar de um elevaram o escore a 0.0190, +0.0054 (+0.0009 a +0.0066) em relação à média das execuções em nadir e dentro da amplitude delas. Mover a câmera para uma inclinação de 26 a 52 graus, mantido todo o resto, deu uma média de 0.0555 (0.0502 a 0.0614) ao longo de três sementes e uma eficácia de 8.9 por cento (8.2 a 9.7); a diferença pareada sobre as médias foi de +0.0419 (+0.0368 a +0.0470), uma razão de 4.08 sobre um denominador próximo do piso, com amplitudes que não se sobrepuseram. S-oblique-six, que alterou em conjunto assentamentos, faixa de inclinação, figuras e posicionamento da câmera, alcançou uma média de 0.0966 e uma eficácia de 15.5 por cento, +0.0411 (+0.0367 a +0.0462) acima de S-oblique com amplitudes que não se sobrepuseram, um passo do mesmo tamanho absoluto. A dispersão entre sementes de assentamento foi 1.4 vez a dispersão entre sementes de treino, abaixo do fator de 2 fixado como o sinal de que a cena domina, e subconjuntos aninhados dos quadros de treino deram, como médias de três sementes, 0.0618 com 30 quadros e 0.0904 com 120 e 0.0966 com 152, 0.0140 de mAP50 por duplicação.

Em HERIDAL, no tamanho de entrada pareado de 1,152 pixels (Tabela 6), R marcou 0.2927 (0.2618 a 0.3247); o checkpoint selecionado no conjunto de teste urbano marcou 0.3185, +0.0258 (+0.0113 a +0.0421), 8.8 por cento contra 1.4 no benchmark urbano, uma vantagem que o teto reportado remove. Diante dele a ordem das duas geometrias se inverteu: S-nadir-150 alcançou 0.1997 na média de três execuções, 68.2 por cento de R (59.0 a 78.9), e S-oblique 0.1341, 45.8 por cento (40.6 a 52.6), uma diferença de -0.0656 (-0.0840 a -0.0471) que passou pelas leituras por intervalo e relativa, mas não pela leitura por semente, com as execuções em nadir espalhando-se de 0.0926 a 0.2672 e sobrepondo-se às execuções oblíquas; com seis assentamentos o modelo em nadir alcançou 0.2488, 85.0 por cento de R (73.2 a 98.2), contra 0.1477 de S-oblique-six, 50.5 por cento (44.6 a 57.3).

O treino em ladrilhos degradados, a quarta verificação do Experimento A, moveu os escores zero-shot em pequenas quantias e sem direção consistente, uma execução de treino por modelo degradado contra a média das três execuções limpas: S-oblique-six subiu +0.0070 (+0.0022 a +0.0119) no benchmark urbano, 7.3 por cento, e S-nadir-150 subiu +0.0192 (+0.0077 a +0.0309) em HERIDAL, 9.6 por cento, enquanto as outras duas células não se moveram (-0.0004, -0.0019 a +0.0010; -0.0000, -0.0105 a +0.0096). Ambos os ganhos ficam dentro da amplitude das três execuções limpas: os intervalos pareados medem a variação entre imagens com os treinos fixados, não entre treinos, de modo que artefatos de sensor explicam no máximo uma pequena parte da lacuna, à espera das execuções adicionais.

Tabela 6. Detecção zero-shot de pessoas no benchmark nadir, HERIDAL (1,647 imagens, 3,229 pessoas, nadir de 40 a 65 m), no tamanho de entrada pareado de 1,152 pixels e no tamanho do protocolo de 1,280: mAP50 com o intervalo de 95 por cento por reamostragem de imagens, sobre a média das execuções de treino onde um modelo foi treinado três vezes, a amplitude entre essas execuções e a fração de R com seu intervalo de 95 por cento por reamostragem pareada, sendo R treinado e selecionado no benchmark urbano.

Modelo	Execuções	mAP50 a 1,152 (intervalo de 95%)	Amplitude entre execuções	Fração de R	mAP50 a 1,280
R, checkpoint selecionado fora do conjunto de teste (1,106 imagens reais de VisDrone-DET train)	1	0.2927 (0.2618 a 0.3247)	uma execução	100%	0.3026
R, checkpoint selecionado no conjunto de teste urbano	1	0.3185 (0.2843 a 0.3543)	uma execução	108.8% (103.8 a 114.5)	0.3353
S-nadir-150	3	0.1997 (0.1713 a 0.2306)	0.0926 a 0.2672	68.2% (59.0 a 78.9)	0.1682
S-nadir-150-six	1	0.2488 (0.2116 a 0.2865)	uma execução	85.0% (73.2 a 98.2)	0.2208
S-oblique	3	0.1341 (0.1149 a 0.1555)	0.1092 a 0.1476	45.8% (40.6 a 52.6)	0.1422
S-oblique-six	3	0.1477 (0.1265 a 0.1715)	0.1079 a 0.1847	50.5% (44.6 a 57.3)	0.1418

5.3 Experimento B: pré-treino sintético e treino conjunto contra um início genérico

Dada a fatia de 5 ou 10 por cento de imagens reais, o modelo que partiu dos pesos sintéticos terminou abaixo do início genérico em ambos os volumes, sob o cronograma de treino original e sob cada um de três outros, e o mesmo ocorreu com o modelo treinado em imagens sintéticas e reais em conjunto (Tabelas 7 e 8, Figura 4). A 5 por cento o início genérico liderou por +0.0716 (+0.0658 a +0.0780) sobre as médias de três sementes e a 10 por cento por +0.0614 (+0.0553 a +0.0679); a expectativa fixada antes da execução, de que a diferença seria maior no volume menor, falhou no sinal, sendo a diferença mais negativa ali e estreitando-se à medida que os dados reais cresciam. Os modelos conjuntos terminaram 0.0637 (0.0562 a 0.0700) e 0.0281 (0.0214 a 0.0346) abaixo do início genérico, além da margem fixada de antemão.

Na grade de cronogramas de treino a execução de controle reproduziu exatamente o modelo genérico (0.5220) e, sob cada cronograma, em ambos os volumes, o início genérico ficou acima do sintético com um intervalo que excluía zero; com cada início no cronograma que sua fatia de seleção preferiu, a liderança genérica ampliou-se para +0.1369 (+0.1290 a +0.1465) a 5 por cento e +0.1129 (+0.1044

a +0.1230) a 10 (Tabela 8).



Figura 3. Figuras portando um fuzil, uma pistola, nada, uma vassoura, um pedaço de cano ou um guarda-chuva fechado a 1.14, 2.44 e 4.88 cm por pixel (35, 75 e 150 m). Cada uma é recortada de um quadro renderizado do corpus de 35 m, de seus gêmeos ou de seus quadros reservados e redimensionada ao mesmo tamanho sem suavização, de modo que cada recorte mostra os pixels que o detector recebe. As figuras que portam objetos foram escolhidas a olho, sob luz clara, como aquelas cujo item está na mão próximo da horizontal; em muitos quadros o item aponta acentuadamente para baixo ou não está na empunhadura (Seção 4.6).

5.4 Experimento C: a distinção entre armado e desarmado por GSD

A 2.44 e 1.14 cm por pixel os detectores de três classes classificaram como armados entre 0.165 e 0.273 dos objetos confundíveis em suas partições de seleção (Tabela 9), e reduzir a GSD à metade não diminuiu essa taxa em corpora pareados treinados por 60 épocas, 0.253 contra 0.125 em quadros reservados (Tabela 10). O gêmeo a 150 m passou em sua condição de validade, fixada de antemão como encontrar ao menos metade das figuras anotadas, somente quando treinado por mais tempo, encontrando 0.663 delas em seus 80 quadros reservados contra 0.498 após o primeiro treino; ali classificou como armados 0.457 das figuras armadas, 0.245 (0.204 a 0.289) dos objetos confundíveis e 0.205 das pessoas desarmadas, um d′ contra objetos de 0.58 (0.38 a 0.78), comparado com 0.97 do gêmeo a 75 m e 0.77 do modelo de 35 m nos mesmos índices de quadros (Tabela 11), e figuras portando a pistola de 0.20 m foram classificadas como armadas a 0.50. Uma pistola que ocupa 4 por 0.6 pixels nessa GSD (Seção 5.1) não pode ser resolvida, de modo que uma taxa acima da dos objetos confundíveis se lê como uma pista que não é a própria arma, sendo a pose de porte fixada por arma a candidata (Seção 4.2.2); o controle pareado por comprimento abaixo isola o comprimento, não essa pista.

Sob o mesmo orçamento a vantagem da GSD intermediária não se sustentou. Treinado por 120 épocas como o gêmeo a 150 m, o modelo de 35 m classificou como armados 0.192 (0.152 a 0.236) dos objetos e o gêmeo a 75 m 0.222 (0.174 a 0.271), contra 0.245 a 150 m, e nenhuma diferença entre os três passou pela leitura por intervalo; o gêmeo a 75 m classificou mais objetos como armados sob o cronograma de treino mais longo, +0.088 (+0.044 a +0.131) nos mesmos quadros contra a média de suas três execuções a 60 épocas, e o d′ contra objetos foi de 0.88, 0.85 e 0.58 a 1.14, 2.44 e 4.88 cm por pixel, com a queda a 150 m passando apenas pela leitura relativa (Tabela 11). Pela regra fixada antes da execução, de que o U se sustenta somente se o gêmeo a 75 m sob o cronograma mais longo ainda classificar menos objetos como armados do que ambos os vizinhos pela leitura por intervalo, o U ao longo

Tabela 7. Ajuste fino em 5 e 10 por cento da partição de treino do benchmark a partir do modelo sintético e de pesos genéricos, e treino conjunto a partir de pesos genéricos nas mesmas imagens reais com os 890 ladrilhos sintéticos: mAP50 em VisDrone-DET val com intervalos de 95 por cento por reamostragem de imagens, por semente de treino onde repetido.

Dados reais de treino, semente	F-synthetic (a partir de S-oblique-six)	F-generic (a partir de COCO)	F-joint
5 por cento (324 imagens), semente 0	0.4424 (0.4260 a 0.4587)	0.5220 (0.5045 a 0.5403)	0.4607 (0.4444 a 0.4789)
5 por cento, semente 1	0.4608 (0.4441 a 0.4784)	0.5228 (0.5056 a 0.5410)	treinado uma vez
5 por cento, semente 2	0.4554 (0.4400 a 0.4721)	0.5285 (0.5114 a 0.5474)	treinado uma vez
10 por cento (647 imagens), semente 0	0.5095 (0.4935 a 0.5264)	0.5709 (0.5535 a 0.5883)	0.5428 (0.5259 a 0.5610)

Tabela 8. Ajuste fino sob quatro cronogramas de treino, por fatia de dados reais e início: mAP50 do modelo ajustado em VisDrone-DET val, o conjunto de teste (primeira semente de treino), e, entre parênteses, o mAP50-95 de seu melhor checkpoint na fatia de seleção, na qual o cronograma de cada início foi escolhido; a célula escolhida está em negrito. O cronograma original treina toda a rede a uma taxa de aprendizado de 0.002; os outros congelam o backbone, reduzem a taxa a 0.0002, ou ambos, sob o mesmo orçamento de 30 épocas.

Fatia, início	Original	Backbone congelado	Taxa de aprendizado 0.0002	Ambos
5 por cento, sintético	**0.4424 (0.1480)**	0.2808 (0.0901)	0.3103 (0.1019)	0.2028 (0.0585)
5 por cento, genérico	0.5220 (0.1802)	0.5467 (0.1886)	**0.5746 (0.2230)**	0.5410 (0.1915)
10 por cento, sintético	**0.5095 (0.1743)**	0.3209 (0.1053)	0.3875 (0.1258)	0.2241 (0.0681)
10 por cento, genérico	0.5709 (0.1951)	0.5772 (0.2030)	**0.6224 (0.2451)**	0.5644 (0.2001)

das três GSDs foi em parte um artefato do orçamento de treino; o que se sustenta é uma taxa de falso alarme sobre objetos cotidianos de 0.19 a 0.25 em toda GSD. O controle pareado por comprimento testou então o que sustentava a separação remanescente. Com todo objeto confundível redimensionado para entre 0.62 e 1.05 m, o modelo treinado a 150 m deixou de separar figuras armadas de objetos em seus 80 novos quadros, d′ de 0.12 (-0.09 a 0.32), contra 0.58 do gêmeo original: pela regra fixada antes da execução, a separação a 4.88 cm por pixel dependia do comprimento. A 75 m a separação sobreviveu sem o comprimento, d′ de 0.44 (0.24 a 0.65), mas caiu pela metade, -0.53 (-0.82 a -0.25), e a taxa de objetos subiu de 0.125 para 0.201 (0.150 a 0.255). Cruzados, os modelos originais avaliados nos quadros pareados por comprimento medem quanto de seu falso alarme o comprimento explica sem retreino: o gêmeo a 150 m classificou como armados 0.368 (0.320 a 0.418) dos objetos de comprimento de arma de fogo, contra 0.245 dos objetos originais, e o gêmeo a 75 m 0.208 (0.162 a 0.255) contra 0.125. Cada modelo de controle foi treinado uma vez.

Nos 50 quadros reservados do teste de arma não vista, S-nadir-75 classificou como armados 0.434 das figuras armadas,

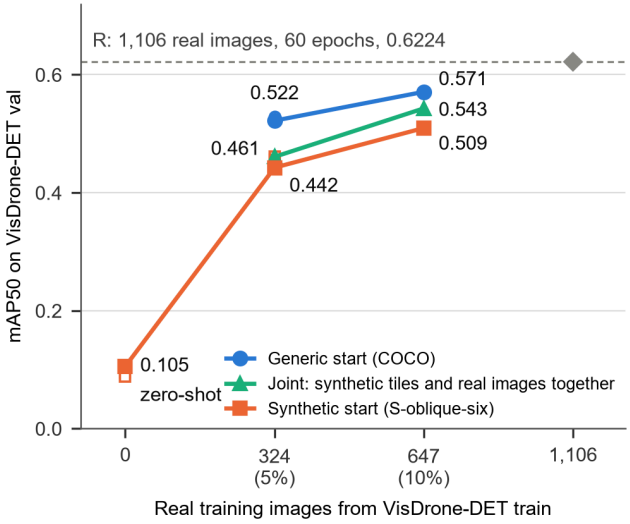


Figura 4. mAP50 em VisDrone-DET val em função do número de imagens reais de treino para as três maneiras de usar o corpus sintético uma vez que existam imagens reais: como pesos iniciais (início sintético), misturado ao conjunto de treino (conjunto) ou de modo nenhum (início genérico). Marcadores preenchidos: a primeira execução de treino; marcadores vazados: as duas execuções adicionais onde existem. Linha tracejada: R, treinado em 1,106 imagens reais por duas vezes mais épocas.

0.152 (0.113 a 0.196) dos objetos confundíveis e 0.068 das pessoas desarmadas. A revocação foi de 0.400 nas cinco armas de fogo de treino e de 0.466 nas duas não vistas, uma razão de 1.16 (intervalo aproximado de 95 por cento de 0.88 a 1.54) contra o limiar de 0.80 abaixo do qual o resultado de 75 m seria retirado. Entre os objetos, o guarda-chuva fechado, de 0.88 m de comprimento, foi classificado como armado a 0.38, vassouras a 0.10 e pedaços de cano a 0.11; portar cada objeto nas poses das armas e em seus ângulos moveu a taxa de objetos de 0.154 para 0.137 nos 227 objetos pareáveis caixa a caixa (teste exato de McNemar, p = 0.56), de modo que a reserva quanto à pose de porte, a ser retirada se a taxa pareada não subisse, foi retirada.

Ao longo de três sementes a diferença na taxa de objetos entre S-nadir-35 e seu gêmeo manteve-se nos quadros reservados, com amplitudes separadas, enquanto as diferenças para armados e desarmados cruzaram o zero. Varrendo o limiar de confiança (Figura 5), o limiar que maximizou o F1 da classe armada ficou entre 0.30 e 0.50 e elevou a precisão para armados de 0.37 a 0.46 no padrão para 0.47 a 0.66; em nenhum limiar algum modelo excedeu uma revocação de armados de 0.65, e a maior revocação de armados a uma taxa de objetos de 0.10 ou menos foi de 0.42.

5.5 Experimento D: desempenho por regime de iluminação

Em quadros sintéticos, o sol forte foi o mais fraco dos seis regimes para o S-nadir-150 em ambas as medidas, e o céu encoberto o mais forte em mAP50, em nível com o sol baixo, cujas sombras são igualmente nítidas (Tabela 12); em revocação, o intervalo do sol forte ficou inteiramente abaixo dos de céu encoberto, chuva e sol baixo. O especialista em sol forte superou o modelo de todos os regimes nos mesmos 20 quadros de sol forte em +0.0818 (+0.0377 a +0.1243) de revocação, mas, contra esse modelo sob céu encoberto, a comparação fixada

Tabela 9. A distinção entre armado e desarmado na partição de seleção de cada corpus de três classes (27, 35 e 24 quadros), sob o protocolo da Seção 4.7, a confiança 0.25, com intervalos de 95 por cento por reamostragem de quadros. d′ com a correção log-linear; sem ela os valores contra objetos são 0.83, 0.78 e 0.90 e contra pessoas desarmadas 1.24, 1.14 e 1.16. O mAP50 de três classes é sobre quadros inteiros.

Grandeza	S-nadir-75 (75 m, 2.44 cm/px)	S-nadir-35 (35 m, 1.14 cm/px)	Gêmeo de S-nadir-35 a 75 m (2.44 cm/px)
mAP50, três classes	0.579	0.514	0.508
Revocação, armado	0.547 (0.476 a 0.627)	0.569 (0.492 a 0.646)	0.471 (0.397 a 0.558)
Precisão, armado	0.386	0.415	0.440
Objeto confundível classificado como armado	0.237 (0.183 a 0.289)	0.273 (0.202 a 0.353)	0.165 (0.100 a 0.230)
Pessoa desarmada sem portar nada classificada como armada	0.131 (0.073 a 0.188)	0.168 (0.101 a 0.235)	0.109 (0.044 a 0.174)
d′ contra objetos confundíveis	0.83 (0.54 a 1.13)	0.77 (0.46 a 1.10)	0.89 (0.58 a 1.32)
d′ contra pessoas desarmadas	1.23	1.12	1.14

como decisiva, sua revocação diferiu em -0.0572 (-0.1252 a +0.0067), intervalo que inclui zero, e seu mAP50 (0.7422) permaneceu abaixo de 0.7906, em 6.5 por cento.

6. Discussão

6.1 Respondendo às questões de pesquisa à luz da literatura

RQ1. Sem imagens reais de treino, a detecção no benchmark urbano alcançou 2.2 por cento do teto para a aquisição de referência, 8.9 com o mesmo assentamento visto obliquamente e 15.5 para o S-oblique-six; a geometria da câmera sozinha moveu a cifra tanto quanto tudo o que foi acrescentado depois dela, +0.0419 de mAP50 contra +0.0411 para seis assentamentos, uma faixa de inclinação mais íngreme e figuras novas vistas obliquamente, e +0.0054 em nadir, com o tamanho aparente pareado, de modo que o que resta é a forma do alvo (Seção 6.2). No HERIDAL a ordem se inverteu, 68.2 contra 45.8 por cento, pelas leituras por intervalo e relativa, mas não pela leitura por semente, de modo que nesses dois benchmarks o fator se lê como o custo de um descasamento entre a geometria do corpus e a do conjunto de teste, com as reservas da Seção 6.5. Kiefer, Ott e Zell (2022) obtiveram de 1.2 a 10.2 pontos de mAP50 no mesmo benchmark apenas com imagens de motor de jogo; o S-oblique-six situa-se no extremo superior dessa faixa, sobre denominadores que diferem.

RQ2. Com as fatias de 5 ou 10 por cento, o corpus sintético não acrescentou acurácia em nenhum dos dois usos, como pré-treino ou misturado, sob o cronograma de treino original e com cada ponto de partida em seu cronograma de treino preferido (Seção 5.3); a diferença, mais negativa no volume menor, concorda com a transferência negativa da Seção 2.2 (Shen et al., 2023a, 2023b; Yim et al., 2026).

RQ3. Apenas com imagens sintéticas, o detector separou figuras portando uma arma de fogo de figuras portando um objeto alongado comum só parcialmente em toda GSD, e aquilo pelo qual as separava mudou com a GSD. Sob o mesmo orçamento, os três modelos chamaram de armados 19.2, 22.2 e 24.5 por cento dos objetos, e nenhuma diferença entre eles passou pela leitura por intervalo, de modo que as GSDs mais finas não reduziram a confusão e a vantagem da intermediária após 60 épocas foi em parte orçamento de treino. A 4.88 cm por pixel, onde a figura mediana mede 17.6 por 17.5 pixels e a arma de fogo mais larga tem um pixel de largura (Seção 5.1), a separação foi mais fraca, e quando a todo objeto se deu o comprimento de uma arma de fogo ela caiu ao acaso: pela hipótese fixada de antemão, o que o detector separava nessa GSD era comprimento, não a forma de uma arma de fogo, e sem retreino ele classificou como armados 37 por cento dos objetos com comprimento de arma de fogo. A 2.44 cm

Tabela 10. S-nadir-35 contra seu gêmeo a 75 m, todos os demais ajustes mantidos. Taxas em que cada classe é classificada como armada a confiança 0.25 nas partições de seleção (35 e 24 quadros) e nos 80 quadros reservados de cada corpus, com diferenças, intervalos de 95 por cento por reamostragem de quadros independentemente em cada lado e p de um teste de duas proporções. As linhas seguintes trazem amplitudes e médias sobre três sementes de treino, a taxa de objetos em limiares de IoU mais estritos e d′ (correção log-linear) com intervalos por reamostragem de quadros.

Grandeza	S-nadir-35 (1.14 cm/px)	Gêmeo a 75 m (2.44 cm/px)	Diferença (intervalo de 95%)
Objeto confundível classificado como armado, partição de seleção	0.273	0.165	+0.108 (+0.015 a +0.211), p = 0.06
Objeto confundível classificado como armado, 80 quadros reservados	0.253 (74 de 292)	0.125 (36 de 288)	+0.128 (+0.071 a +0.194), p = 0.0001
Pessoa armada classificada como armada, partição de seleção	0.569	0.471	+0.099 (-0.022 a +0.217), p = 0.15
Pessoa armada classificada como armada, 80 quadros reservados	0.543	0.432	+0.112 (+0.031 a +0.192)
Pessoa desarmada classificada como armada, partição de seleção	0.168	0.109	+0.059 (-0.038 a +0.154), p = 0.22
Pessoa desarmada classificada como armada, 80 quadros reservados	0.156	0.140	+0.015 (-0.040 a +0.073)
d′ contra objetos confundíveis, partição de seleção	0.77 (0.46 a 1.10)	0.89 (0.58 a 1.32)	
d′ contra objetos confundíveis, 80 quadros reservados	0.77 (0.57 a 0.99)	0.97 (0.77 a 1.20)	
Taxa de objetos sobre três sementes de treino, partição de seleção (amplitude; média)	0.231 a 0.273; 0.248	0.132 a 0.242; 0.179	amplitudes se sobrepõem; +0.068 (+0.002 a +0.142), 38.1%
Taxa de objetos sobre três sementes de treino, 80 quadros reservados (amplitude; média)	0.202 a 0.253; 0.222	0.097 a 0.181; 0.134	amplitudes separadas; +0.087 (+0.044 a +0.136), 64.9%
Taxa de objetos, partição de seleção, a IoU 0.60 e 0.75	0.223 e 0.132	0.165 e 0.132	em nível a 0.75

Tabela 11. Os modelos de três classes a 1.14, 2.44 e 4.88 cm por pixel nos 80 quadros reservados de cada corpus, que compartilham seus índices de quadros: fração das figuras anotadas encontradas em qualquer classe, as taxas em que cada classe é classificada como armada a confiança 0.25, e d′ contra objetos confundíveis (correção log-linear), da primeira execução de treino de cada modelo, sendo o modelo a 150 m aquele treinado por mais tempo. As linhas inferiores dão os dois controles da Seção 4.6: o modelo de 35 m e seu gêmeo a 75 m retreinados por 120 épocas, e os modelos pareados por comprimento, cada um avaliado nos 80 novos quadros em que todo objeto tem de 0.62 a 1.05 m de comprimento, com os modelos originais avaliados nesses mesmos quadros. Intervalos por 1,000 reamostragens de quadros; os intervalos das duas primeiras linhas estão na Tabela 10.

Modelo (GSD, cm/px)	Figuras encontradas	Armado classificado como armado	Objeto classificado como armado	Desarmado classificado como armado	d′ vs objeto
S-nadir-35 (1.14)	0.684	0.543	0.253	0.156	0.77
Gêmeo a 75 m (2.44)	0.766	0.432	0.125	0.140	0.97
Gêmeo a 150 m (4.88)	0.663	0.457	0.245 (0.204 a 0.289)	0.205	0.58 (0.38 a 0.78)
S-nadir-35, 120 épocas (1.14)	0.739	0.503	0.192 (0.152 a 0.236)	0.137	0.88 (0.65 a 1.09)
Gêmeo a 75 m, 120 épocas (2.44)	0.761	0.537	0.222 (0.174 a 0.271)	0.178	0.85 (0.65 a 1.07)
Gêmeo a 75 m, objetos no comprimento de arma de fogo, em seus novos quadros (2.44)	0.806	0.347	0.201 (0.150 a 0.255)	0.093	0.44 (0.24 a 0.65)
Gêmeo a 75 m, original, nos quadros pareados por comprimento (2.44)	0.797	0.508	0.208 (0.162 a 0.255)	0.146	0.83 (0.63 a 1.05)
Gêmeo a 150 m, objetos no comprimento de arma de fogo, 120 épocas, em seus novos quadros (4.88)	0.623	0.188	0.158 (0.121 a 0.201)	0.102	0.12 (-0.09 a 0.32)
Gêmeo a 150 m, original, nos quadros pareados por comprimento (4.88)	0.710	0.464	0.368 (0.320 a 0.418)	0.168	0.25 (0.03 a 0.44)

por pixel a separação sobreviveu sem o comprimento, mas caiu pela metade, e a pista além do comprimento não está estabelecida (Seção 5.4). Nenhum limiar para declarar a capacidade presente foi fixado de antemão, de modo que o veredito é uma leitura dos pontos de operação da Seção 5.4: uma capacidade não demonstrada e, a 4.88 cm por pixel, uma separação que se mostrou assentada em uma pista que qualquer objeto longo fornece.

6.2 GSD e ponto de vista contra o fotorrealismo

Essas medições reenquadram um problema de projeto normalmente posto como um problema de realismo da cena. A GSD

Tabela 12. Desempenho por regime nos 120 quadros reservados do corpus principal (nadir, 150 m, 4.88 cm por pixel), 20 por regime: mAP50 nos ladrilhos de cada regime e revocação a confiança 0.25 em quadros inteiros, para o S-nadir-150, treinado em todos os seis regimes, com intervalos de 95 por cento por reamostragem de quadros, e para o modelo treinado apenas sob sol forte.

Regime	mAP50, todos os regimes	Revocação a 0.25, todos os regimes	Intervalo de 95%	mAP50, só sol forte	Revocação a 0.25, só sol forte
Sol forte	0.675	0.657	0.591 a 0.720	0.742	0.739
Céu encoberto denso	0.755	0.768	0.714 a 0.816	0.754	0.749
Chuva	0.759	0.789	0.748 a 0.827	0.728	0.747
Névoa	0.780	0.726	0.697 a 0.757	0.652	0.569
Sol baixo	0.790	0.814	0.768 a 0.854	0.794	0.776
Céu encoberto	0.791	0.796	0.760 a 0.827	0.796	0.759

define o tamanho do alvo, e a altitude é apenas um dos meios de se chegar a uma GSD: em seu ajuste grande-angular, a câmera de referência dá 9.76 cm por pixel a 150 m e chega a 4.88 com zoom de 2.0 vezes, 2.44 a 4.0 vezes e 1.14 a 8.6 vezes, com sua pegada encolhendo para 22 por 12 m no último caso, 73 vezes menos área. O ponto de vista define a forma, propriedade de onde a câmera é posicionada, não de como a cena é construída: o corpus a construir é aquele cuja geometria casa com a aquisição em que será usado. Ambos deixam sem medir o custo da própria geometria genérica, que Liao et al. (2026) situam em 27.0 pontos de mAP50 para sua classe de objeto.

6.3 Implicações para a prática de aquisição

Sobre iluminação, ambas as medições são sintéticas: o contraste contra a desordem visual local foi mais alto sob céu encoberto e mais baixo sob sol forte e chuva, e nos quadros reservados o sol forte foi o regime mais fraco, oito pontos de mAP50 abaixo do seguinte, mas o sol baixo, cujas sombras são igualmente nítidas, pontuou em nível com o céu encoberto, e a ablação situou o déficit no corpus de treino, e não na luz: um detector destinado a funcionar sob sol alto precisa de imagens suficientes de sol forte em seu conjunto de treino. Especificações de levantamento aéreo pedem imagens sem nuvens e elevação solar de ao menos 30 graus (National Geodetic Survey, 2002) ou 15 (RICS, 2021), selecionando o regime que um detector treinado nos seis em partes iguais achou mais fraco aqui, e orientações de mapeamento por drone preferem luz de céu encoberto para reconstrução (Maes, 2025); para a detecção de pessoas, os resultados não favorecem nenhuma das luzes em si, e a chuva é um regime de treino, não de voo, já que no Brasil a operação sob precipitação está excluída de todo modo (Departamento

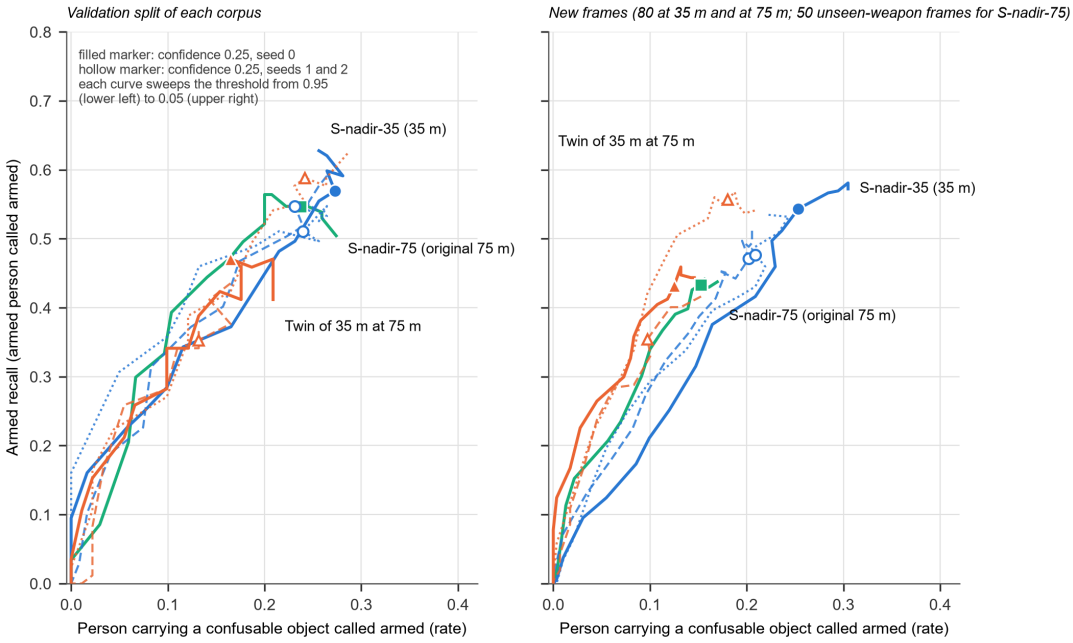


Figura 5. Revocação de armados contra a taxa de objetos à medida que o limiar de confiança percorre de 0.95 (inferior esquerdo) a 0.05 (superior direito), para S-nadir-75, S-nadir-35 e o gêmeo a 75 m. Esquerda: partição de seleção de cada corpus. Direita: quadros reservados (80 a 35 m e a 75 m; os 50 quadros de armas não vistas para o S-nadir-75). Marcadores preenchidos: confiança 0.25, semente 0; marcadores vazados: confiança 0.25, sementes 1 e 2 (curvas tracejada e pontilhada).

de Controle do Espaço Aéreo, 2026).

6.4 Uso dual: a taxa de falso alarme como estimativa de dano, e a condição que ela produz

A taxa de objetos da Seção 5.4 é uma estimativa sintética, não medida em imagens reais, de com que frequência um detector desse tipo marca como armada uma figura portando um objeto doméstico, o erro que a Seção 3.4 coloca no núcleo ético. Dois testes fixados de antemão, executados no corpus original de 75 m, constataram que ali ela não é um artefato do gerador (no corpus de 35 m e seus gêmeos a pose de porte continua sendo uma pista, Seção 4.2.2): a revocação em modelos de arma de fogo que o detector nunca vira não ficou abaixo da revocação nos modelos com que foi treinado, e portar todo objeto confundível exatamente como se porta uma arma deixou a taxa de objetos inalterada. Um terceiro teste dá à taxa um mecanismo: com todo objeto confundível escalado ao comprimento de uma arma de fogo, o detector treinado a 150 m classificou como armados 0.368 deles sem retreino, e um modelo retreinado com tais objetos deixou de separar as duas classes nessa GSD; sobre um território em que moradores carregam vassouras, canos e esteiras enroladas, aquilo a que um alerta de "armado" a 4.88 cm por pixel responde é o comprimento do que se carrega.

A precisão de 0.37 a 0.46 para a classe armada no limiar padrão (Seção 5.4) foi medida em quadros em que figuras portando uma arma de fogo eram aproximadamente tão frequentes quanto figuras portando um objeto; sobre um território em que moradores carregando uma ferramenta superam de longe em número quem quer que carregue uma arma de fogo, a parcela de alertas que recai sobre um morador cresce com esse desequilíbrio, e um alerta de "armado" é a recomendação algorítmica mais propensa a confirmar o julgamento que precede uma decisão de usar a força (Seção 3.3). Os termos deste estudo são, portanto, o que um comando policial, o tribunal que supervisiona operações sob a ADPF 635 e os moradores podem exigir de uma alegação aérea de pessoa armada antes que ela entre em tal decisão: (i) a GSD e a geometria de visada em que a alegação foi testada; (ii) a taxa em que pessoas desarmadas portando objetos comuns são classificadas como armadas em imagens não usadas no treino; (iii) o ponto de operação em que essa taxa vale; e (iv) o resultado em armas de fogo que o sistema não tinha visto. Cada um foi medido aqui e ficou aquém; nenhum é uma recomendação de voar, e os moradores são a parte sobre quem recaem os erros.

6.5 Limitações e trabalhos futuros

(1) Os benchmarks: o VisDrone consiste em cenas urbanas densas de aquisição não controlada a uma altura estimada de 30 a 100 m com a câmera majoritariamente inclinada (Kiefer, Messmer, & Zell, 2021), não uma favela, e o HERIDAL é área selvagem a uma GSD mais fina; nenhum benchmark aéreo público com caixas de pessoas em terra reproduz uma vista ao nadir a 150 m sobre uma cidade. (2) Realismo sintético: um único sensor sem ruído, desfoque de movimento, profundidade de campo, rolling shutter ou aberração cromática; degradar os ladrilhos de treino moveu as pontuações zero-shot em 7 a 10 por cento relativos em duas de quatro células e em nada nas outras duas, dentro da dispersão entre execuções de treino (Seção 5.2), de modo que artefatos de sensor explicam no máximo uma pequena parte da lacuna; o custo da geometria genérica é citado, e não medido. (3) Seis malhas rigadas por execução de renderização, cinco modelos de arma contra nove objetos. (4) A maioria dos modelos foi treinada uma única vez, entre eles os dois controles e os modelos degradados, e a grade de cronogramas de treino é uma busca pequena, não um ajuste. (5) Os modelos de três classes são avaliados na

partição que selecionou seu checkpoint, exceto nos quadros reservados, de modo que essas pontuações são tetos, e não evidência de transferência, e toda eficácia é uma fração de um teto para o protocolo (Seção 4.5), não do melhor alcançável no benchmark. (6) Os objetos diferem das armas em como os itens longos são angulados, nos materiais e, no corpus de 35 m e seus gêmeos, na pose de porte; o controle pareado por comprimento mostrou que o comprimento responde por toda a separação a 4.88 cm por pixel e por cerca de metade a 2.44, e o que as diferenças restantes contribuem não está isolado. (7) O estudo é escrito de fora do território e a partir de um enquadramento de segurança, e nenhum depoimento de morador foi coletado. (8) Sementes adicionais para os modelos treinados uma única vez, a semente do assentamento variada para o corpus ao nadir e avaliação zero-shot em benchmarks ao nadir de pessoas, SeaDronesSee (Varga, Kiefer, Messmer, & Zell, 2022) ou o Stanford Drone Dataset (Robicquet, Sadeghian, Alahi, & Savarese, 2016), completariam o desenho; qualquer imagem do território está do outro lado de uma revisão ética independente e de um engajamento comunitário fora da instituição policial, e o desenho desse processo, não um refinamento do detector, é o próximo passo.

7. Conclusão

Treinado apenas com imagens sintéticas de um assentamento denso, um detector recupera uma pequena fração da acurácia de detecção de pessoas que imagens reais de treino dão em um benchmark aéreo urbano público, entre 2.2 e 15.5 por cento do teto a depender da aquisição; a geometria da câmera sozinha move essa fração tanto quanto tudo o que foi acrescentado depois dela, em coerência com a forma aparente do alvo, e não com seu tamanho, e em um benchmark nadir a ordem se inverte pela leitura pareada, com faixas de execuções sobrepostas, de modo que o que se transfere é a geometria que casa com o conjunto de teste (RQ1). Uma vez disponíveis 324 ou 647 imagens reais de treino, o corpus sintético não acrescenta acurácia, como pré-treino ou misturado (RQ2). Apenas com imagens sintéticas, um detector separa uma figura portando uma arma de fogo de uma portando um objeto alongado cotidiano só parcialmente, classificando como armado aproximadamente de um em cada cinco a um em cada quatro objetos em toda GSD sob o mesmo orçamento de treino, e a 4.88 cm por pixel a separação que resta assenta-se no comprimento, não na forma de uma arma de fogo; a distinção não foi testada em imagens reais (RQ3).

A alegação de que um sistema consegue distinguir do ar uma pessoa armada de uma desarmada é, nas altitudes e com os sensores aqui descritos, uma alegação que pode ser verificada antes de ser acreditada, e este artigo se recusa a fazê-la. Nenhuma alegação aérea de que uma pessoa está armada deveria entrar em uma decisão de usar a força sem declarar a GSD e a geometria de visada em que foi testada, a taxa em que pessoas desarmadas portando objetos comuns são classificadas como armadas em imagens que o sistema não tinha visto, e o ponto de operação em que essa taxa vale. Um sistema que consegue distinguir uma pessoa armada de uma desarmada e um sistema que é seguro apontar para o Jacarezinho são objetos distintos; o segundo é decidido por um processo que inclui os moradores do território, e ele não ocorreu.

Declarações

Ética. O estudo não envolveu participantes humanos nem coletou dados pessoais, de modo que nenhuma aprovação de comitê de ética foi exigida. Nenhuma imagem de moradores ou do território do Jacarezinho foi coletada ou usada, nenhuma entra no gerador, nos corpora ou em qualquer medição aqui relatada, e nenhuma coordenada em nível de endereço é publicada. Os únicos dados reais são dois benchmarks públicos que contêm imagens de pessoas, usados sob os termos de seus distribuidores, e nenhuma imagem deles é aqui reproduzida; os corpora sintéticos são renderizados a partir de cenas geradas proceduralmente e de ativos de domínio público, e as figuras humanas neles são malhas renderizadas, de modo que os dados sintéticos não contêm pessoa alguma. O estudo não entrega uma ferramenta operacional.

Uso dual. A capacidade que este estudo mede serve à decisão de usar força letal, e um sistema que marcasse moradores desarmados como armados causaria dano na proporção de seu uso. O artigo publica as condições sob as quais essa capacidade não foi demonstrada, disponibiliza o gerador apenas mediante solicitação direta aos autores e não libera corpora nem pesos, não relata informação em nível de endereço, e afirma que qualquer uso sobre o território depende de uma revisão ética independente e de um processo com seus moradores.

Conflito de interesse. Os autores declaram não haver conflito de interesse. Nenhum autor tem ou teve qualquer vínculo de emprego, consultoria ou relação contratual com a Polícia Civil do Estado do Rio de Janeiro, com qualquer outra instituição policial, ou com qualquer fornecedor de aeronaves não tripuladas ou de software de detecção.

Financiamento. Esta pesquisa não recebeu nenhum financiamento específico de agências de fomento dos setores público, comercial ou sem fins lucrativos, nem bolsa de estudos.

Disponibilidade de dados. O gerador procedural de cenas e seu código estão disponíveis junto aos autores mediante solicitação direta; os corpora sintéticos e os pesos treinados não são liberados; os dois benchmarks são públicos e são distribuídos por seus autores. A Seção 4.8 declara o que os autores podem regenerar a partir do que cada imagem registra e o que um leitor pode verificar sem o gerador.

Declaração sobre IA generativa e tecnologias assistidas por IA. Durante a preparação deste trabalho, os autores usaram o Claude (Anthropic) para revisar o texto, para checar e corrigir informações factuais e ortografia, e para auxiliar no monitoramento das execuções de treino. Após o uso dessa ferramenta, os autores revisaram e editaram o conteúdo conforme necessário e assumem total responsabilidade pelo conteúdo da publicação.

Agradecimentos. Os autores agradecem a Fábio H. P. Guimarães, perito da Polícia Civil do Estado do Rio de Janeiro, que em 2022 propôs detectar pessoas armadas em imagens aéreas de drone com uma rede neural convolucional treinada com dados sintéticos de motor de jogo, proposta da qual este trabalho se origina, e ao Prof. Claudio Miceli de Farias, da Universidade Federal do Rio de Janeiro, que orientou o projeto de pesquisa e extensão de 2022 em que essa proposta foi desenvolvida.

Referências

Agência Brasil. (2025, April 3). STF retoma julgamento da ADPF das Favelas [Supreme Court resumes the ADPF das Favelas trial]. https://agenciabrasil.ebc.com.br/justica/noticia/2025-04/stf-retoma-julgamento-da-adpf-das-favelas-0

Agrawal, P., Ratnoo, A., & Ghose, D. (2017). Inverse optical flow based guidance for UAV navigation through urban canyons. *Aerospace Science and Technology, 68*, 163-178. https://doi.org/10.1016/j.ast.2017.05.012

Alcadipani, R., Lotta, G., & Cohen, N. (2024). Natural born violence? Understanding street-level bureaucrats' use of violence: Police officers and protests. *Public Administration Review, 84*(1), 100-114. https://doi.org/10.1111/puar.13670

AlJundi, Z., Alsubaie, S., Faheem, M. H., Almarashi, R. M., Qazi, E.-u.-H., & Kim, J. H. (2025). Dangerous objects detection using deep learning and first responder drone. *International Journal of Digital Crime and Forensics, 16*(1), 1-18. https://doi.org/10.4018/ijdcf.367034

Barisic, A., Petric, F., & Bogdan, S. (2022). Sim2Air: Synthetic aerial dataset for UAV monitoring. *IEEE Robotics and Automation Letters, 7*(2), 3757-3764. https://doi.org/10.1109/LRA.2022.3147337

Berwaldt, N. L. P., Bettker, R. V., & Pozzer, C. T. (2020). Procedural generation of favela layouts on arbitrary terrains. In *2020 19th Brazilian Symposium on Computer Games and Digital Entertainment (SBGames)* (pp. 136-144). https://doi.org/10.1109/SBGames51465.2020.00027

Blender Foundation. (2026). *Blender* (Version 5.2) [Computer software]. https://www.blender.org

Božić-Štulić, D., Marušić, Ž., & Gotovac, S. (2019). Deep learning approach in aerial imagery for supporting land search and rescue missions. *International Journal of Computer Vision, 127*(9), 1256-1278. https://doi.org/10.1007/s11263-019-01177-1

Chen, Z., Liu, Y., Hu, S., Zhang, X., & Pan, Y. (2025). Deterring street crimes using aerial police: Data-driven joint station deployment and patrol path planning for policing UAVs. *Drones, 9*(6), Article 449. https://doi.org/10.3390/drones9060449

CNN. (2026, September 9). Drones are becoming organized crime's weapon of choice in Latin America. Governments are struggling to keep up. https://www.cnn.com/2026/09/09/americas/drones-crime-latin-america-latam-intl

Couto, C., & Figueiredo, C. (2025, October 30). Polícia atualiza para 121 o número de mortos em megaoperação no Rio [Police update the death toll of the mega-operation in Rio to 121]. CNN Brasil. https://www.cnnbrasil.com.br/nacional/sudeste/rj/policia-atualiza-numero-de-mortos-em-megaoperacao-no-rio/

da Silva, A. A., Kormann da Silva, I. F., & Westerholt, R. (2024). Mapping the margins: A systematic scoping review of the impact of digital mapping on public participation in informal settlements. *Habitat International, 147*, Article 103040. https://doi.org/10.1016/j.habitatint.2024.103040

Dare, P. M. (2005). Shadow analysis in high-resolution satellite imagery of urban areas. *Photogrammetric Engineering & Remote Sensing, 71*(2), 169-177. https://doi.org/10.14358/PERS.71.2.169

Departamento de Controle do Espaço Aéreo. (2026). *ICA 100-40: Aeronaves não tripuladas e o acesso ao espaço aéreo brasileiro* [ICA 100-40: Unmanned aircraft and access to Brazilian airspace] (Portaria DECEA nº 2.094/DNOR8, de 18 de março de 2026). Comando da Aeronáutica. https://www.gov.br/defesa/pt-br/assuntos/aerolevantamento/arquivos/2026/ica-100-40-publicada-port-2094-dnor8-18-03-2026-bca-058-30-03-2026.pdf

DJI. (2019). *Zenmuse Z30 user manual* (Version 1.2). https://dl.djicdn.com/downloads/Z30/20190906/Z30_User_Manual_EN.pdf

Du, D., Qi, Y., Yu, H., Yang, Y., Duan, K., Li, G., Zhang, W., Huang, Q., & Tian, Q. (2018). The unmanned aerial vehicle benchmark: Object detection and tracking. In *Computer Vision, ECCV 2018* (Lecture Notes in Computer Science, Vol. 11214, pp. 375-391). Springer. https://doi.org/10.1007/978-3-030-01249-6_23

Faheem, M. H., Haq, Q. E. U., Khan, T. M., & Kim, J. H. (2025). Deep-learning-based weapon detection using drones equipped with infrared and color cameras. *International Journal of Digital Crime and Forensics, 17*(1), 1-16. https://doi.org/10.4018/ijdcf.393088

Fichino, D. (2025). *Operação Contenção: Análise da operação policial mais letal da história do estado do Rio de Janeiro à luz dos padrões internacionais de uso da força e de investigações* [Operation Containment: Analysis of the deadliest police operation in the history of the state of Rio de Janeiro in light of international standards on the use of force and investigations] [Report]. Justiça Global. https://www.global.org.br/wp/wp-content/uploads/2025/11/2025-11-07-JG-RELATO-RIO-OPERACAO-CONTENCAO_VF-compactado.pdf

Fórum Brasileiro de Segurança Pública. (2025). *19º Anuário Brasileiro de Segurança Pública: 2025* [19th Brazilian Public Security Yearbook: 2025]. https://publicacoes.forumseguranca.org.br/handle/fbsp/279

Fórum Brasileiro de Segurança Pública. (2026). *Anuário Brasileiro de Segurança Pública 2026* [Brazilian Public Security Yearbook 2026] (Ano 20). https://forumseguranca.org.br/wp-content/uploads/2026/07/anuario-2026.pdf

Frazier, A. (2016). Commentary: Unmanned aircraft systems: What constitutes a surveillance? *Public Administration Review, 76*(4), 660-661. https://doi.org/10.1111/puar.12549

Gao, C., & Riccucci, N. M. (2026). Artificial intelligence in policing and perceived legitimacy: Does gender representation make a difference? *Public Administration Review*. Advance online publication. https://doi.org/10.1111/puar.70214

Gevaert, C. M., Persello, C., Sliuzas, R., & Vosselman, G. (2016). Classification of informal settlements through the integration of 2D and 3D features extracted from UAV data. *ISPRS Annals of the Photogrammetry, Remote Sensing and Spatial Information Sciences, III-3*, 317-324. https://doi.org/10.5194/isprs-annals-III-3-317-2016

Gram-Hansen, B. J., Helber, P., Varatharajan, I., Azam, F., Coca-Castro, A., Kopackova, V., & Bilinski, P. (2019). Mapping informal settlements in developing countries using machine learning and low resolution multi-spectral data. In *Proceedings of the 2019 AAAI/ACM Conference on AI, Ethics, and Society (AIES '19)* (pp. 361-368). ACM. https://doi.org/10.1145/3306618.3314253

Grillo, I. (2014, September 10). Brazil's Red Command and the police who fight them. InSight Crime. https://insightcrime.org/news/analysis/brazils-red-command-rio-police-favelas-slums/

Hautus, M. J. (1995). Corrections for extreme proportions and their biasing effects on estimated values of d′. *Behavior Research Methods, Instruments, & Computers, 27*(1), 46-51. https://doi.org/10.3758/BF03203619

He, K., Girshick, R., & Dollár, P. (2019). Rethinking ImageNet pre-training. In *2019 IEEE/CVF International Conference on Computer Vision (ICCV)* (pp. 4917-4926). https://doi.org/10.1109/ICCV.2019.00502

Headley, A. M., Baker, D. B., & Kang, I. (2025). Body-worn cameras, police arrests, and bureaucratic discretion: A large-scale causal analysis across the United States. *Public Administration Review, 85*(4), 989-1003. https://doi.org/10.1111/puar.13927

Hinterstoisser, S., Lepetit, V., Wohlhart, P., & Konolige, K. (2019). On pre-trained image features and synthetic images for deep learning. In *Computer Vision, ECCV 2018 Workshops* (Lecture Notes in Computer Science, pp. 682-697). Springer. https://doi.org/10.1007/978-3-030-11009-3_42

Hnoohom, N., Chotivatunyu, P., & Jitpattanakul, A. (2022). ACF: An armed CCTV footage dataset for enhancing weapon detection. *Sensors, 22*(19), Article 7158. https://doi.org/10.3390/s22197158

Human Rights Watch. (2021, May 31). Brazil: Investigate Rio police command for deadly raid. https://www.hrw.org/news/2021/05/31/brazil-investigate-rio-police-command-deadly-raid

Instituto Brasileiro de Geografia e Estatística. (2024). *Censo Demográfico 2022: Favelas e comunidades urbanas: Resultados do universo* [2022 Population Census: Favelas and urban communities: Universe results]. IBGE. https://censo2022.ibge.gov.br/apps/pgi/pdf/Censo%20Demogr%C3%A1fico%202022%20-%20Favelas%20e%20Comunidades%20Urbanas%20-%20Resultados%20do%20universo%20-%202024%2011%2006.pdf

Instituto de Segurança Pública do Rio de Janeiro. (n.d.). *Estatísticas de segurança: Série histórica anual no estado desde 1991 (taxas por 100 mil habitantes)* [Security statistics: Annual historical series for the state since 1991 (rates per 100,000 inhabitants)] [Data set]. Retrieved September 30, 2026, from https://www.ispdados.rj.gov.br/Arquivos/BaseEstadoTaxaAno.csv

Jocher, G., & Qiu, J. (2024). *Ultralytics YOLO11* (Version 11.0.0) [Computer software]. https://github.com/ultralytics/ultralytics

Kiefer, B., Messmer, M., & Zell, A. (2021). Diminishing domain bias by leveraging domain labels in object detection on UAVs. In *2021 20th International Conference on Advanced Robotics (ICAR)* (pp. 523-530). https://doi.org/10.1109/ICAR53236.2021.9659357

Kiefer, B., Ott, D., & Zell, A. (2022). Leveraging synthetic data in object detection on unmanned aerial vehicles. In *2022 26th International Conference on Pattern Recognition (ICPR)* (pp. 3564-3571). https://doi.org/10.1109/ICPR56361.2022.9956710

Kim, Y., Park, J., Yoon, D., Jung, N., & Jeon, M. (2026). G-MAD: A game-based data generation framework for multi-view RGB-T aerial object detection. arXiv. https://arxiv.org/abs/2607.19942

Lessing, B. (2008). As facções cariocas em perspectiva comparativa [Rio's criminal factions in comparative perspective]. *Novos Estudos CEBRAP*, (80), 43-62. https://doi.org/10.1590/S0101-33002008000100004

Li, T., Liu, J., Zhang, W., Ni, Y., Wang, W., & Li, Z. (2021). UAV-Human: A large benchmark for human behavior understanding with unmanned aerial vehicles. In *2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)* (pp. 16261-16270). https://doi.org/10.1109/CVPR46437.2021.01600

Li, Z., Yellapragada, S., Bhadresh Doshi, K., Mhasakar, P. M., Fan, H., Wei, J., Blasch, E., Zhang, B., & Ling, H. (2025). CCTV-Gun: Benchmarking handgun detection in CCTV images. In *Dynamic Data Driven Applications Systems* (Lecture Notes in Computer Science, Vol. 15514, pp. 171-181). Springer. https://doi.org/10.1007/978-3-031-94895-4_18

Liao, F., Liu, Y., Xu, W., Wang, X., Liu, G., Yang, K., & Li, J. (2026). Bridging the Sim2Real gap in UAV remote sensing: A high-fidelity synthetic data framework for vehicle detection. *Remote Sensing, 18*(2), Article 361. https://doi.org/10.3390/rs18020361

Lim, J., Al Jobayer, M. I., Baskaran, V. M., Lim, J. M., See, J., & Wong, K. (2021). Deep multi-level feature pyramids: Application for non-canonical firearm detection in video surveillance. *Engineering Applications of Artificial Intelligence, 97*, Article 104094. https://doi.org/10.1016/j.engappai.2020.104094

Lin, T.-Y., Maire, M., Belongie, S., Hays, J., Perona, P., Ramanan, D., Dollár, P., & Zitnick, C. L. (2014). Microsoft COCO: Common objects in context. In *Computer Vision, ECCV 2014* (Lecture Notes in Computer Science, pp. 740-755). Springer. https://doi.org/10.1007/978-3-319-10602-1_48

Maes, W. H. (2025). Practical guidelines for performing UAV mapping flights with snapshot sensors. *Remote Sensing, 17*(4), Article 606. https://doi.org/10.3390/rs17040606

MakeHuman Community. (2026). *MPFB* (Version 2.0.17) [Computer software]. https://static.makehumancommunity.org/mpfb.html

McCormac, J., Handa, A., Leutenegger, S., & Davison, A. J. (2017). SceneNet RGB-D: Can 5M synthetic images beat generic ImageNet pre-training on indoor segmentation? In *2017 IEEE International Conference on Computer Vision (ICCV)* (pp. 2697-2706). https://doi.org/10.1109/ICCV.2017.292

Meijer, A., Lorenz, L., & Wessels, M. (2021). Algorithmization of bureaucratic organizations: Using a practice lens to study how context shapes predictive policing systems. *Public Administration Review, 81*(5), 837-846. https://doi.org/10.1111/puar.13391

Misse, M. (2011). Crime organizado e crime comum no Rio de Janeiro: Diferenças e afinidades [Organized crime and common crime in Rio de Janeiro: Differences and affinities]. *Revista de Sociologia e Política, 19*(40), 13-25. https://doi.org/10.1590/S0104-44782011000300003

Mistler-Ferguson, S. (2022, January 27). Brazil tries to reclaim Rio's favelas: Ad infinitum. InSight Crime. https://insightcrime.org/news/brazil-tries-reclaim-rio-favelas-ad-infinitum/

National Geodetic Survey. (2002). *General specifications for aeronautical surveys, Volume II: Airport aerial photography* (Version 14). National Oceanic and Atmospheric Administration. https://www.ngs.noaa.gov/AERO/GenSpecVol_II_v14.pdf

Pérez-Hernández, F., Tabik, S., Lamas, A., Olmos, R., Fujita, H., & Herrera, F. (2020). Object detection binary classifiers methodology based on deep learning to identify small objects handled similarly: Application in video surveillance. *Knowledge-Based Systems, 194*, Article 105590. https://doi.org/10.1016/j.knosys.2020.105590

Poly Haven. (n.d.). *Poly Haven: The public 3D asset library*. Retrieved November 2, 2026, from https://polyhaven.com

Prakash, A., Boochoon, S., Brophy, M., Acuna, D., Cameracci, E., State, G., Shapira, O., & Birchfield, S. (2019). Structured domain randomization: Bridging the reality gap by context-aware synthetic data. In *2019 International Conference on Robotics and Automation (ICRA)* (pp. 7249-7255). https://doi.org/10.1109/ICRA.2019.8794443

Pyrrö, P. (2021). *HERIDAL dataset in keras-retinanet PASCAL VOC format* (Version 0.0.1) [Data set]. Zenodo. https://doi.org/10.5281/zenodo.5662351

Pyrrö, P., Naseri, H., & Jung, A. (2021). Rethinking drone-based search and rescue with aerial person detection. arXiv. https://arxiv.org/abs/2111.09406

Rasoulie, F., & Pashazadeh, S. (2026). 3D UAV path optimization using a task-allocation and archive-guided mutation particle swarm optimization algorithm. *Scientific Reports, 16*(1), Article 24356. https://doi.org/10.1038/s41598-026-42372-8

RioOnWatch. (2019, May 3). Jacarezinho from a resident's view. https://rioonwatch.org/?p=31407

Robicquet, A., Sadeghian, A., Alahi, A., & Savarese, S. (2016). Learning social etiquette: Human trajectory understanding in crowded scenes. In *Computer Vision, ECCV 2016* (Lecture Notes in Computer Science, Vol. 9912, pp. 549-565). Springer. https://doi.org/10.1007/978-3-319-46484-8_33

Royal Institution of Chartered Surveyors. (2021). *Earth observation and aerial surveys* (6th ed.; RICS professional standard, global, reissued January 2023). RICS. https://www.rics.org/content/dam/ricsglobal/documents/standards/Earth%20observation%20and%20aerial%20surveys_reissue%20Jan%202023.pdf

Ruiz-Santaquiteria, J., Muñoz, J. D., Maigler, F. J., Deniz, O., & Bueno, G. (2024). Firearm-related action recognition and object detection dataset for video surveillance systems. *Data in Brief, 52*, Article 110030. https://doi.org/10.1016/j.dib.2024.110030

Salazar González, J. L., Zaccaro, C., Álvarez-García, J. A., Soria Morillo, L. M., & Sancho Caparrini, F. (2020). Real-time gun detection in CCTV: An open problem. *Neural Networks, 132*, 297-308. https://doi.org/10.1016/j.neunet.2020.09.013

Selten, F., Robeer, M., & Grimmelikhuijsen, S. (2023). 'Just like I thought': Street-level bureaucrats trust AI recommendations if they confirm their professional judgment. *Public Administration Review, 83*(2), 263-278. https://doi.org/10.1111/puar.13602

Shen, Y.-T., Lee, H., Kwon, H., & Bhattacharyya, S. S. (2023a). Progressive transformation learning for leveraging virtual images in training. In *2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)* (pp. 835-844). https://doi.org/10.1109/CVPR52729.2023.00087

Shen, Y.-T., Lee, Y., Kwon, H., Conover, D. M., Bhattacharyya, S. S., Vale, N., Gray, J. D., Leong, G. J., Evensen, K., & Skirlo, F. (2023b). Archangel: A hybrid UAV-based human detection benchmark with position and pose metadata. *IEEE Access, 11*, 80958-80972. https://doi.org/10.1109/ACCESS.2023.3299235

Sithole, L., & Mhangara, P. (2025). Classification of informal settlements using novel object-based machine learning algorithms and drone imagery, Slovo Park, Johannesburg, South Africa. *International Journal of Remote Sensing, 46*(23), 8919-8965. https://doi.org/10.1080/01431161.2025.2518504

Sullivan, J. P., Bunker, R., & da Cruz, J. de A. (2021, May 26). Third generation gangs strategic note no. 36: High casualty civil police raid in Rio de Janeiro's Jacarezinho favela raises human rights concerns. Small Wars Journal. https://smallwarsjournal.com/2021/05/26/third-generation-gangs-strategic-note-no-36-high-casualty-civil-police-raid-rio-de/

Supremo Tribunal Federal. (2025, April 3). ADPF das Favelas: STF homologa parcialmente plano do Estado do Rio de Janeiro para reduzir letalidade policial [ADPF das Favelas: Supreme Court partially approves the State of Rio de Janeiro's plan to reduce police lethality]. https://noticias.stf.jus.br/postsnoticias/adpf-das-favelas-stf-homologa-parcialmente-plano-do-estado-do-rio-de-janeiro-para-reduzir-letalidade-policial/

Tobin, J., Fong, R., Ray, A., Schneider, J., Zaremba, W., & Abbeel, P. (2017). Domain randomization for transferring deep neural networks from simulation to the real world. In *2017 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)* (pp. 23-30). https://doi.org/10.1109/IROS.2017.8202133

Torkst, C., Rangel, P., & Efigenio, J. (2026). *Dual-UAV dataset for detection and localization of armed individuals* [Data set]. Zenodo. https://doi.org/10.5281/zenodo.18746168

Tremblay, J., Prakash, A., Acuna, D., Brophy, M., Jampani, V., Anil, C., To, T., Cameracci, E., Boochoon, S., & Birchfield, S. (2018). Training deep networks with synthetic data: Bridging the reality gap by domain randomization. In *2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW)*. https://doi.org/10.1109/CVPRW.2018.00143

Varga, L. A., Kiefer, B., Messmer, M., & Zell, A. (2022). SeaDronesSee: A maritime benchmark for detecting humans in open water. In *2022 IEEE/CVF Winter Conference on Applications of Computer Vision*

(WACV) (pp. 3686-3696). https://doi.org/10.1109/WACV51458.2022.00374

Wang, D., & Qian, X. (2026). Police UAV path planning method based on improved PSO using AFS and HJS. *Scientific Reports, 16*(1), Article 12417. https://doi.org/10.1038/s41598-026-40670-9

Wang, Z., Dai, Z., Póczos, B., & Carbonell, J. (2019). Characterizing and avoiding negative transfer. In *2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)* (pp. 11285-11294). https://doi.org/10.1109/CVPR.2019.01155

Watson, C. S., & Elliott, J. R. (2025). Narrowing the gap for city building height predictions. *Scientific Reports, 15*(1), Article 29913. https://doi.org/10.1038/s41598-025-15929-2

West, J. P., & Bowman, J. S. (2016). The domestic use of drones: An ethical analysis of surveillance issues. *Public Administration Review, 76*(4), 649-659. https://doi.org/10.1111/puar.12506

Wright, J. E., II, Gaozhao, D., & Houston, B. (2024). Body-worn cameras and representation: What matters when evaluating police use of force? *Public Administration Review, 84*(6), 1117-1133. https://doi.org/10.1111/puar.13746

Xu, G. (2025). A comparative study of drones path planning and bezier curve optimization based on multi-strategy search algorithm. *PLOS One, 20*(7), Article e0326633. https://doi.org/10.1371/journal.pone.0326633

Yan, S., Hsieh, T.-H., & Lai, Y.-C. (2025). Enhancing public safety through integrated UAV and police patrols. *Socio-Economic Planning Sciences, 102*, Article 102334. https://doi.org/10.1016/j.seps.2025.102334

Yim, J., Lee, H., Eum, S., Shen, Y.-T., Zhang, Y., Kwon, H., & Bhattacharyya, S. S. (2026). SynPlay: Large-scale synthetic human data with real-world diversity for aerial-view perception. In *2026 IEEE/CVF Winter Conference on Applications of Computer Vision (WACV)* (pp. 938-947). https://doi.org/10.1109/WACV61042.2026.00098

Zhu, P., Wen, L., Du, D., Bian, X., Fan, H., Hu, Q., & Ling, H. (2022). Detection and tracking meet drones challenge. *IEEE Transactions on Pattern Analysis and Machine Intelligence, 44*(11), 7380-7399. https://doi.org/10.1109/TPAMI.2021.3119563